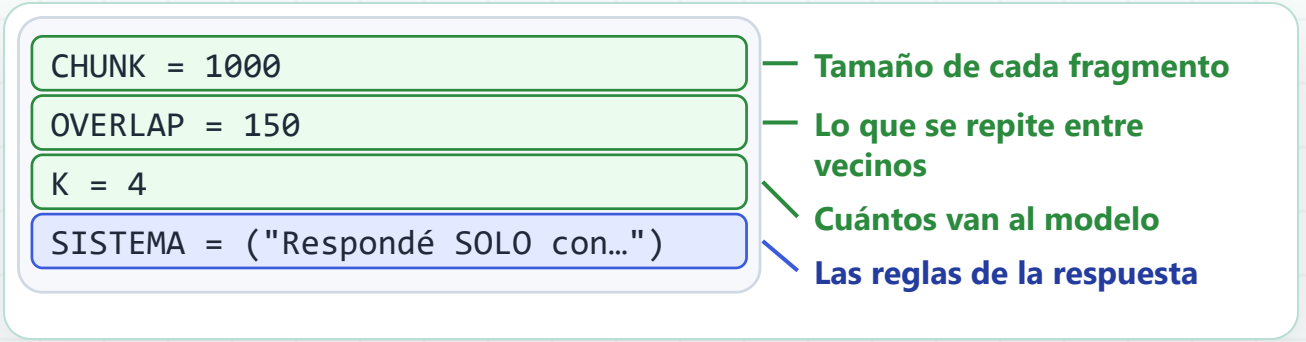
Taller B: sin documentos, con documentos (45 min)

1. **Medí** sin y con documentos.
2. **Cada fallo:** ¿recuperación o generación?
3. **Una perilla:** `CHUNK`, `OVERLAP` o `K`



Práctica M4, En clase.

Primer control · 10–15 min: la tabla de `medir.py`.

Antes de irte, anotá dónde quedaste

- **Estoy en:** qué paso del taller B.
- **Ya tengo:** la tabla sin documentos, con documentos o las dos.
- **El lunes sigo con:** la perilla que voy a cambiar.

Una línea en el chat, para retomar el lunes.

Clínica: una que mejora, una que no

- Una pregunta que mejoró con tus documentos
- Una que no mejoró
- Un límite que no resolviste

Devolución: una fortaleza, un problema y una próxima prueba.

Repaso: de estas dos clases te llevás tres ideas



RAG

buscar antes de responder



Vectores

traer los K más cercanos



Medir

el hit no dice si es verdad

Llegar al documento correcto no alcanza: mirá también la respuesta.

Cierre de v0.2: ¿dónde no ayudó?

¿En qué pregunta buscar en los documentos no ayudó?

¿Qué cambiarías y qué medirías?

Microdefensa: ¿por qué una respuesta que cita un documento puede estar equivocada?

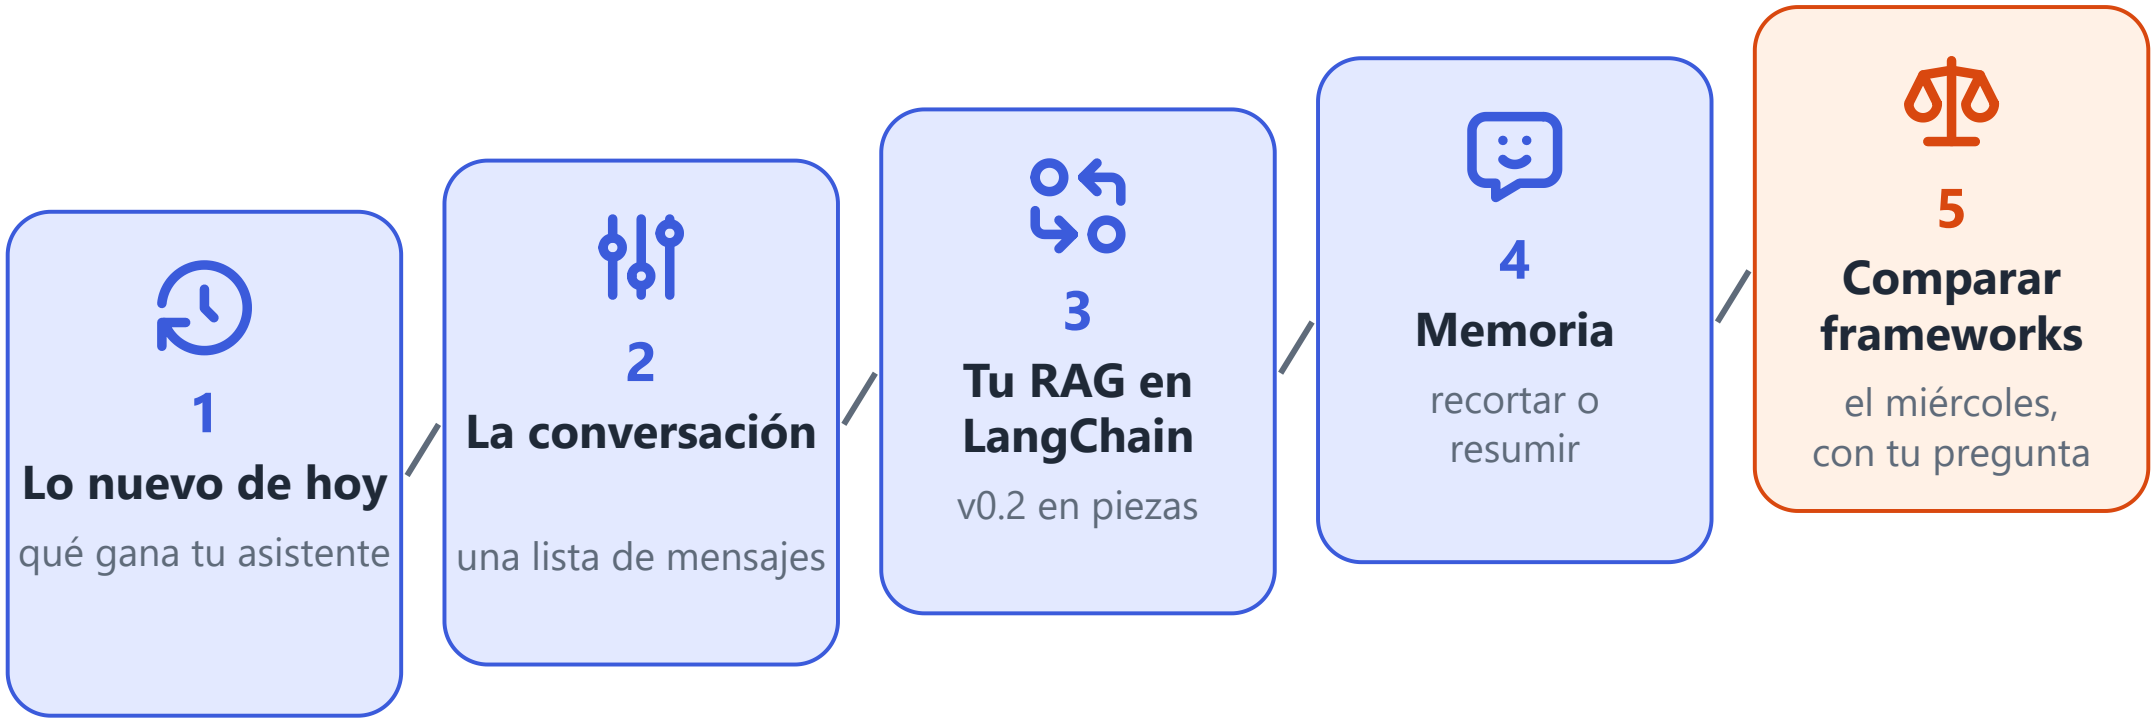
Anotá tu **confianza (1 a 4)**. Entrega de avance 2: `evidencia/v0.2.md` , *push* hasta el mié 11/11, 23:59.

LangChain y memoria

M5: v0.3, LangChain y memoria



De código a mano a piezas armadas



Venís de v0.2, armado a mano. Hoy lo pasás a piezas que encajan y le das memoria.

Hoy cada ejemplo corre en vivo: cuaderno de la clase 4.

Primero solo, después lo discutimos

- Control de lectura individual, 10 min
- Discusión de las respuestas, 5 min

Sin asistentes de IA. 5 preguntas sobre frameworks, memoria y las lecturas. En la discusión, las mismas.

¿Para qué te sirve? Un asistente que sigue la charla

Dónde	Pasa	Lo resuelve
BI	«¿Y por región?» tras el churn	Memoria
Soporte	Cada cliente, su charla	Un hilo por cliente
Equipo	Cambiar Gemini por OpenAI	El framework
Producto	Sumarle herramientas	Piezas que encajan

Para el modelo, una conversación es una lista

```
system     Respondé solo con el contexto y citá el documento.
user       ¿Cómo se calcula el churn?
assistant  Bajas del mes / clientes al inicio [churn].
user       ¿Y por región?
```

- Cada mensaje tiene un rol: instrucciones, vos, el asistente.
- «¿Y por región?» solo se entiende leyendo lo de arriba.

La API no recuerda nada entre pedidos

```
sin = [("system", SISTEMA), ("human", "¿Cómo me llamo?")]
con = [("system", SISTEMA), ("human", "Me llamo Ana."), ("ai", "¡Hola, Ana!"),
       ("human", "¿Cómo me llamo?")]
modelo.invoke(sin).text  # «Todavía no me dijiste tu nombre, ¡así que no lo sé!»
modelo.invoke(con).text  # «Te llamás Ana.»
```

- Memoria = tu programa reenvía la charla en cada pedido.
- ¿Qué pasa si dos personas la usan a la vez?

Cada conversación guarda solo lo suyo

Hilo A
2 preguntas
4 mensajes guardados

≠

Hilo B
1 pregunta
2 mensajes guardados

- **Hilo** = una conversación con su historia: como filtrar los mensajes por hilo.
- ¿Eso es memoria?

El estado: lo que el hilo guarda en cada paso

```
config = {"configurable": {"thread_id": "A"}}
estado = asistente.get_state(config)
[m.type for m in estado.values["messages"]]  # ['human', 'ai', 'human', 'ai']
```

- **Estado** = la foto de la charla: hoy, la lista de mensajes.
- El *checkpointer* la guarda después de cada paso.

Memoria corta y memoria larga

Corta: dentro de una charla
el estado del hilo
***checkpointer*, en tu v0.3**

≠

Larga: entre charlas
datos del usuario: «prefiere tablas»
***store*, por usuario**

Como los filtros de esta sesión y el perfil guardado del usuario.

Dos corridas: el seguimiento acertó una vez

```
corrida 1  Hilo A (seguimiento): NO ENCONTRADO
           Hilo B:               Si el proceso se reinicia, todos los puntos de
                                 control … se pierden [langgraph__persistence].
corrida 2  Hilo A (seguimiento): Si se utiliza MemorySaver o InMemorySaver,
                                 todos los puntos de control se pierden…
           Hilo B:               Cuando el proceso se reinicia, … se pierden…
las dos    Mensajes guardados → hilo A: 4 · hilo B: 2
```

- Probalo: cuaderno en vivo, sección 5
- Buscó solo con «¿y qué pasa con eso?»: hoy lo arreglás.

LangChain: piezas que armás vos

Pieza	Qué hace	En tu v0.3
Modelo	Redacta	`cargar_modelo()`
Prompt y cadena (LCEL)	Arman el pedido, paso a paso	`reformular`
Middleware	Corre antes del modelo	`con_contexto`
Agente	Mensajes → respuesta	`create_agent`
Checkpointer	Guarda cada hilo	`InMemorySaver`

Una función que corre antes del modelo

```
@dynamic_prompt  # la @: LangChain la corre antes de cada llamada al modelo
def con_contexto(pedido: ModelRequest) -> str:
    hits = buscar(pedido.messages[-1].text)  # tu búsqueda de v0.2
    contexto = "\n\n".join(f"[{h['doc']}]\n{h['texto']}" for h in hits)
    return f"{SISTEMA}\n\nContexto:\n{contexto}"
asistente = create_agent(cargar_modelo(), tools=[], middleware=[con_contexto],
                         checkpointer=InMemorySaver())  # guarda cada hilo
```

Busca, arma el contexto y guarda cada hilo. En vivo: sección 1.

LCEL: reescribí el seguimiento antes de buscar

```
reformular = ChatPromptTemplate.from_messages([
    ("system", "Reescribí la última pregunta para que se entienda sola."),
    ("human", "Charla:\n{charla}\n\nÚltima pregunta: {pregunta}"),
]) | cargar_modelo() | StrOutputParser()  # cada | pasa su salida
nueva = reformular.invoke({"charla": charla, "pregunta": "¿Y por región?"})
```

- Entra «¿Y por región?»; sale «¿Cómo se calcula el churn por región?».
- Como los pasos de Power Query: cada uno recibe la salida del anterior.

LangChain no empeoró la suite

v0.2, Chroma
hit 10/11

=

v0.3, LangChain
hit 10/11, mismos fragmentos

Dos corridas (15/10 y 17/10): **sin regresión**. En vivo: sección 3.

Taller: el seguimiento que se pierde (50 min)

1. **Corré** `v03_memoria.py` y `medir.py`: mismo hit
2. **Tu charla:** ¿qué `fuentes` trae el seguimiento?
3. **Reformulá** y mirá de nuevo

Práctica M5, arranque y «En clase», pasos 1 a 3.

Cada turno reenvía toda la charla

Turno	Mensajes que viajan	Con límite
1	1	1
2	3	3
5	9	3
10	19	3

- Pagás tokens por toda la historia, en cada pedido.
- El hilo guarda todo; el límite decide qué ve el modelo.

Recortar o resumir: qué ve el modelo

	Recortar	Resumir
Ve	Los últimos mensajes	Un resumen y los últimos
Cuesta	Parejo	Una llamada más
Pierde	Lo viejo, entero	Detalles
En LangChain	`trim_messages`	`SummarizationMiddleware`

El hilo guarda todo igual: el límite decide qué ve el modelo.

¿Cuánta memoria para tu caso?

Caso	Conviene
Soporte: preguntas cortas	Los últimos mensajes
Un análisis largo con un cliente	Resumir
Datos sensibles	No guardar: un hilo nuevo por pedido

Más memoria responde mejor los seguimientos y cuesta más.

Taller: memoria con límite (35 min)

1. **Aislamiento:** B no guarda lo de A.
2. **Charla larga:** cinco turnos, mirá los tokens.
3. **Recortá** con `trim_messages`: ¿qué olvida?

Práctica M5, pasos 4 a 6. Para casa: ¿recortar o resumir?