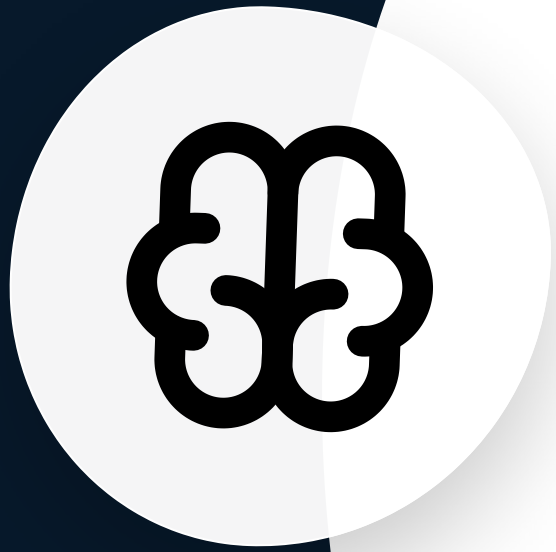
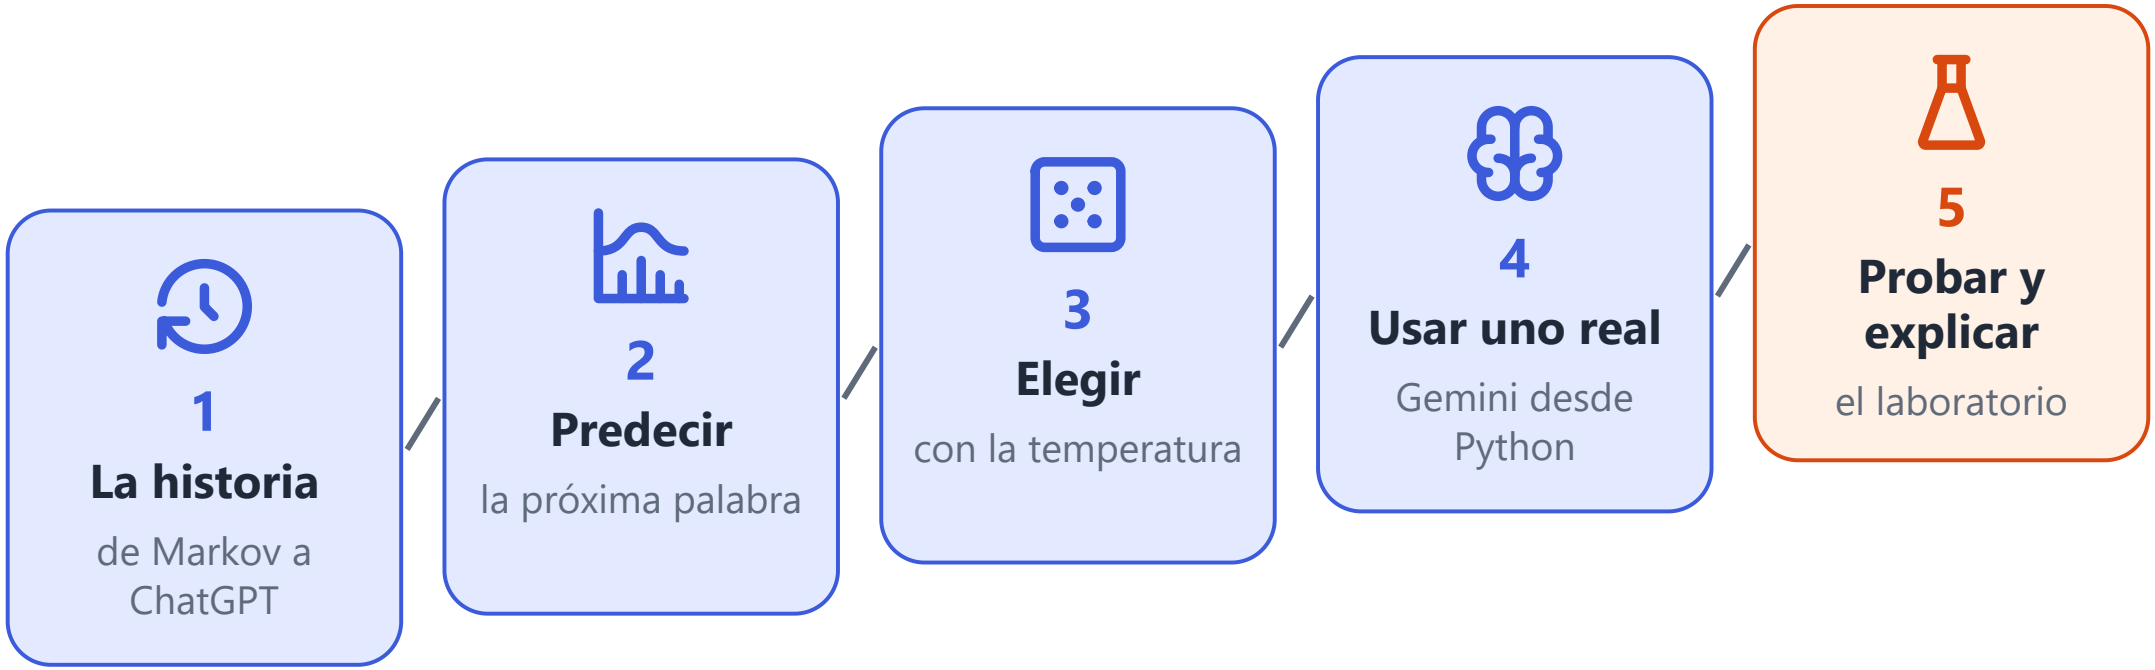
# Qué es un LLM

## M1: Fundamentos de LLMs



# Hoy subimos cinco pasos, sin saltos




Arrancamos de lo que ya sabés de ML.

# Predecí: ¿cómo sigue esta frase?

**«La capital de Uruguay es ? »**



**¿Busca?**



**¿Entiende?**



**¿Predice?**

Anotá tu apuesta y qué probabilidad le das a «Montevideo».

# Posibles respuestas: busca, entiende, predice



## Busca

**no**

No tiene buscador ni internet adentro.



## Entiende

**discutible**

No sabe qué es Uruguay como vos.



## Predice

**sí**

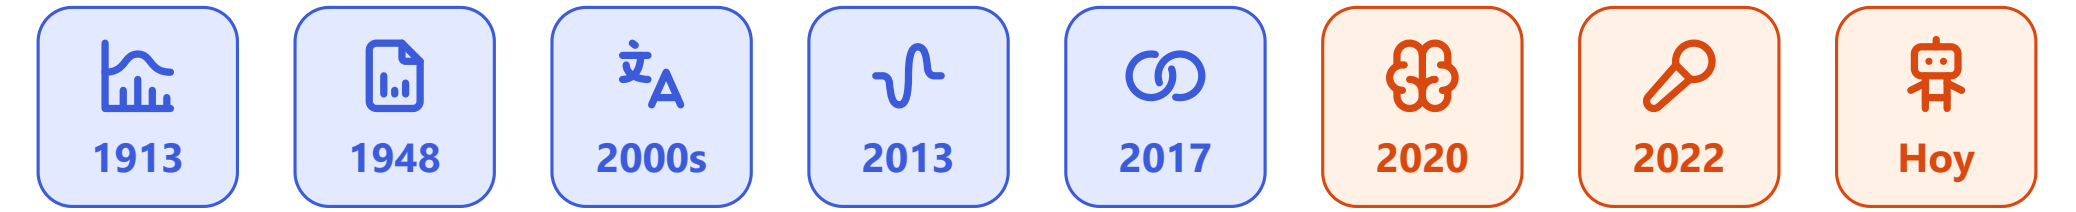
Elige el próximo pedazo más probable.

Lo medimos en un rato.

# Cien años prediciendo lo que sigue

**CONTAR LO QUE SIGUE**

**MODELOS GRANDES**




**Markov**
qué sigue
a cada vocal

**Shannon**
frases
contando palabras

**El celular**
sugiere
la próxima

**word2vec**
cada palabra,
un vector

**Transformer**
mira todo
el texto

**GPT-3**
mucho
más grande

**ChatGPT**
ajustado
para conversar

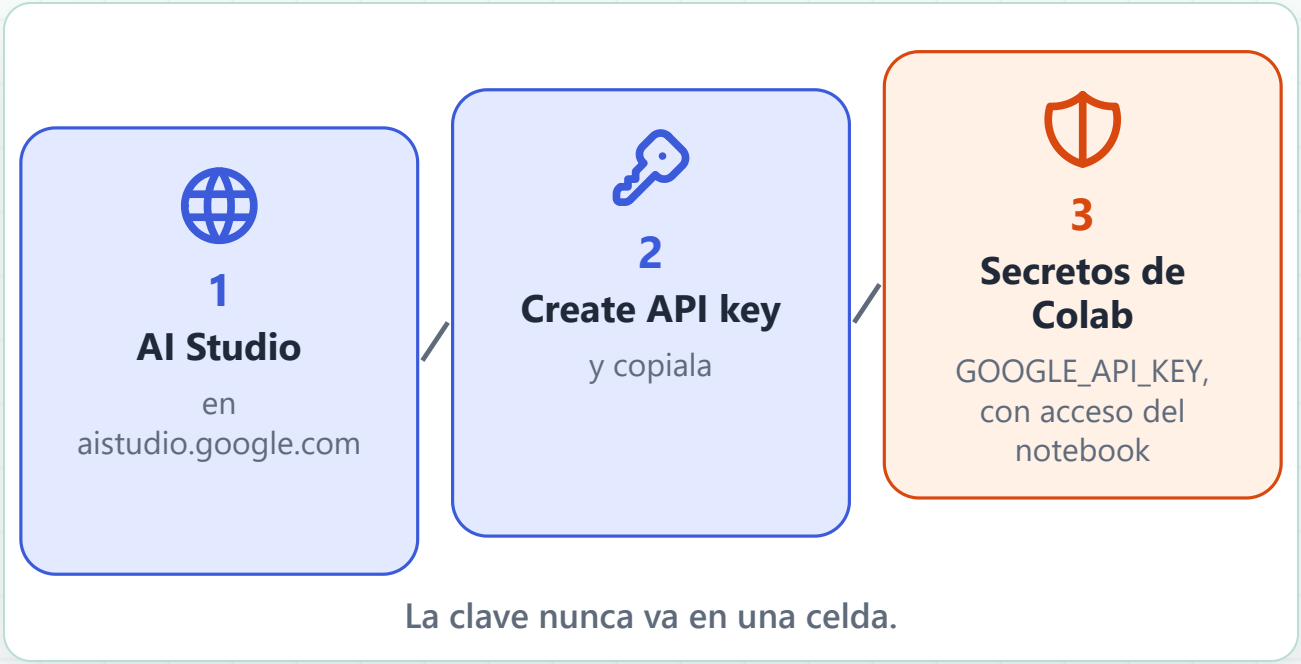
**Agentes**
buscan y
usan herramientas

**La idea nunca cambió: mirar lo anterior y apostar por lo que sigue.**

# Antes del cuaderno: tu clave de Gemini

**Objetivo:** que el cuaderno pueda hablar con Gemini.

1. aistudio.google.com/apikey → **Create API key**.
2. Colab, llave de la izquierda (**Secretos**) → `GOOGLE_API_KEY`, con **Acceso del notebook**.



# Cuaderno, parte 1: Python hablando con Gemini

**Objetivo:** repasar Python mientras le hablás a Gemini.

- En ucu-la: práctica M1 → «Open in Colab».
- Ejercicios 1 a 5 (10 min); el resto, en casa.




**Qué deberías ver:**

`Montevideo` en el 5.

Paso 2 de 5: Predecir

# Cada ejercicio te dice si salió y, si no, una pista

CO m1_python_de_cero.ipynb

```
tema = "un token"   # cuando te salga, probá con otro tema
pregunta = None  # ← tu respuesta
print(pregunta)
revisar("Ejercicio 1", pregunta, f"Explicá en una oración qué es {tema}.",
        'pregunta = f"Explicá en una oración qué es {tema}."')

if pregunta:
    r = modelo.invoke(pregunta)
    print(r.text)
```

```
None
❌ Ejercicio 1: obtuviste None, se esperaba 'Explicá en una oración qué es un token.'
   Pista: pregunta = f"Explicá en una oración qué es {tema}."
```

# ¿Qué es un LLM?

**Le das un texto**
**«La capital de Uruguay es»**

→

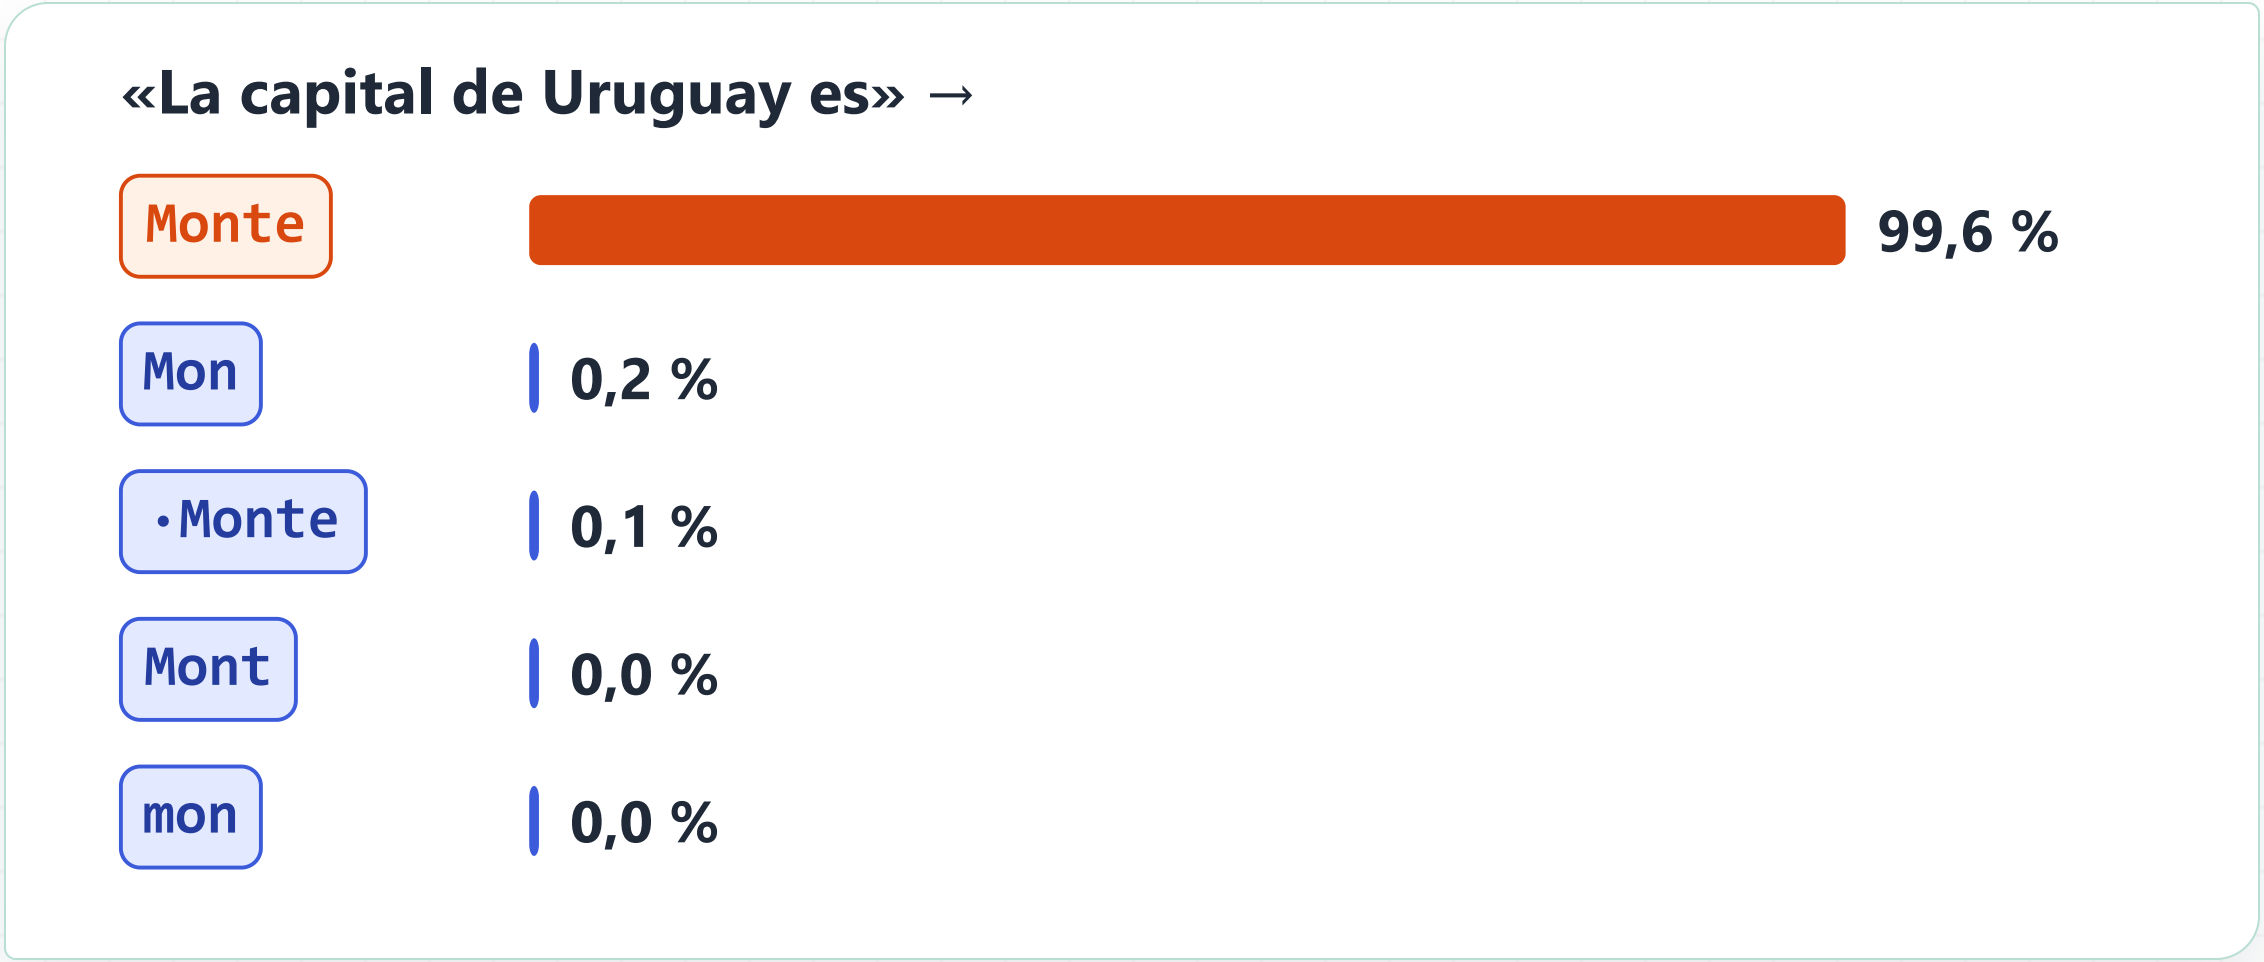
**Te da lo que sigue**
**«Montevideo», con 99,6 %**

- **LLM** = un modelo que predice el próximo pedazo de texto.
- Como el teclado del celular, entrenado con casi todo internet.

# Un LLM es un clasificador que ya conocés

| | Clasificador de ML | LLM |
|---|---|---|
| Entrada | Features | Todo el texto anterior |
| Clases | Pocas | 100 a 260 mil pedazos de palabra (tokens) |
| Salida | Softmax | Softmax |
| Etiqueta | La anota alguien | La palabra que realmente seguía |

# Cada pedazo posible tiene su probabilidad




Ni busca ni entiende: predice.

# Generar es clasificar, agregar y repetir



# Seis vueltas: elige, agrega y repite

| | | | |
|---|---|---|---|
| 1 | El fin de semana fuimos a la | `play` | 72 % |
| 2 | El fin de semana fuimos a la | `play` `a` | 100 % |
| 3 | El fin de semana fuimos a la | `play` `a` `·y` | 91 % |
| 4 | El fin de semana fuimos a la | `play` `a` `·y` `·disfrut` | 91 % |
| 5 | El fin de semana fuimos a la | `play` `a` `·y` `·disfrut` `amos` | 100 % |
| 6 | El fin de semana fuimos a la | `play` `a` `·y` `·disfrut` `amos` `·del` | 83 % |

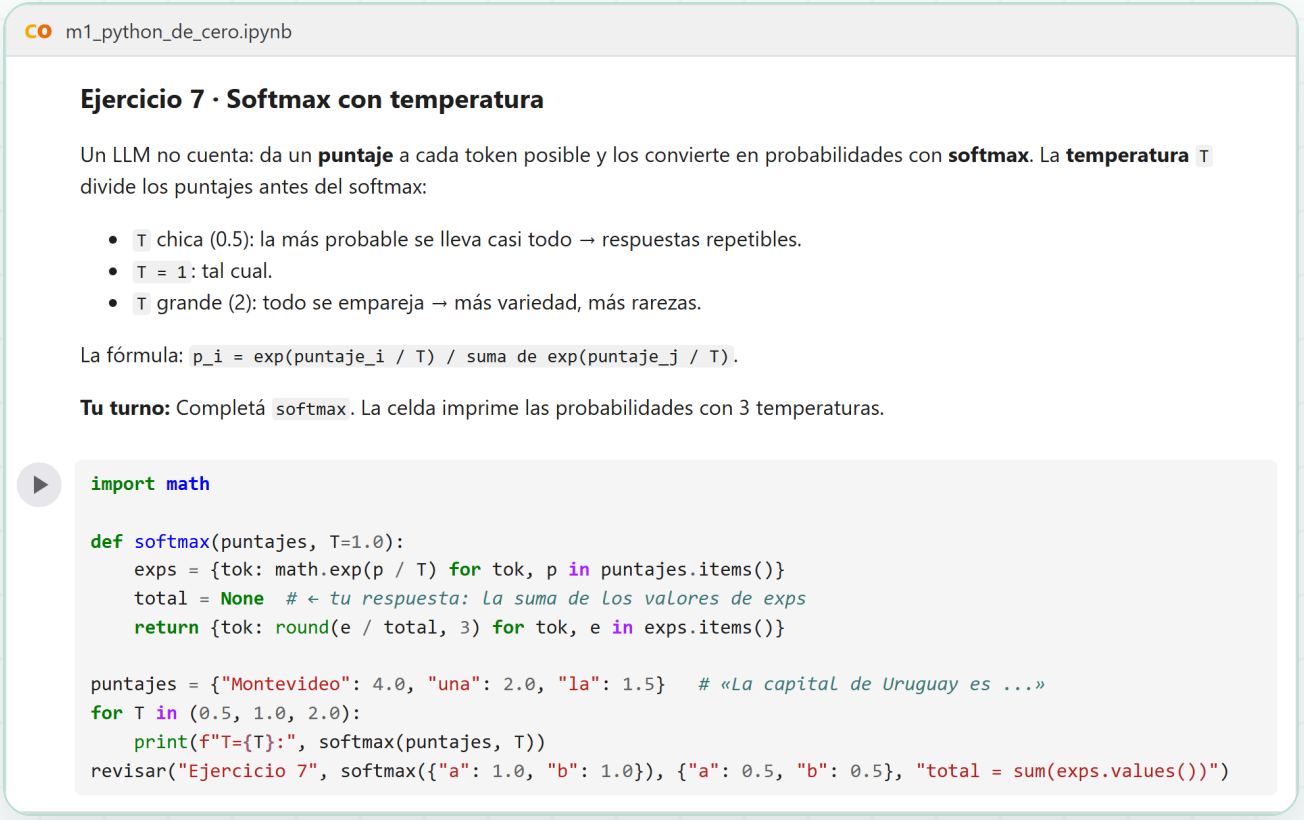
Gana siempre la primera.

# Cuaderno, parte 2: qué palabra sigue

**Objetivo:** armar un modelo de lenguaje de juguete.

Ejercicios 6 y 7, 5 min: la tabla de qué palabra sigue y el softmax con temperatura.

Es lo de 1913 y 1948, hecho por vos.



CO m1_python_de_cero.ipynb

**Ejercicio 7 · Softmax con temperatura**

Un LLM no cuenta: da un **puntaje** a cada token posible y los convierte en probabilidades con **softmax**. La **temperatura** `T` divide los puntajes antes del softmax:

- `T` chica (0.5): la más probable se lleva casi todo → respuestas repetibles.
- `T = 1`: tal cual.
- `T` grande (2): todo se empareja → más variedad, más rarezas.

La fórmula: `p_i = exp(puntaje_i / T) / suma de exp(puntaje_j / T)`.

**Tu turno:** Completá `softmax`. La celda imprime las probabilidades con 3 temperaturas.

```
import math

def softmax(puntajes, T=1.0):
    exps = {tok: math.exp(p / T) for tok, p in puntajes.items()}
    total = None  # ← tu respuesta: la suma de los valores de exps
    return {tok: round(e / total, 3) for tok, e in exps.items()}

puntajes = {"Montevideo": 4.0, "una": 2.0, "la": 1.5}   # «La capital de Uruguay es ...»
for T in (0.5, 1.0, 2.0):
    print(f"T={T}:", softmax(puntajes, T))
revisar("Ejercicio 7", softmax({"a": 1.0, "b": 1.0}), {"a": 0.5, "b": 0.5}, "total = sum(exps.values())")
```

# La temperatura cambia la variedad

**Temperatura (T): un número que estira o aplana las probabilidades antes de sortear.**

### 1. Lo que da el modelo



**playa 75 %**

costa, montaña, campo, ciudad

### 2. T baja: se estira



**playa 97 %**

costa, montaña, campo, ciudad

### 2. T alta: se aplana



**playa 48 %**

costa, montaña, campo, ciudad

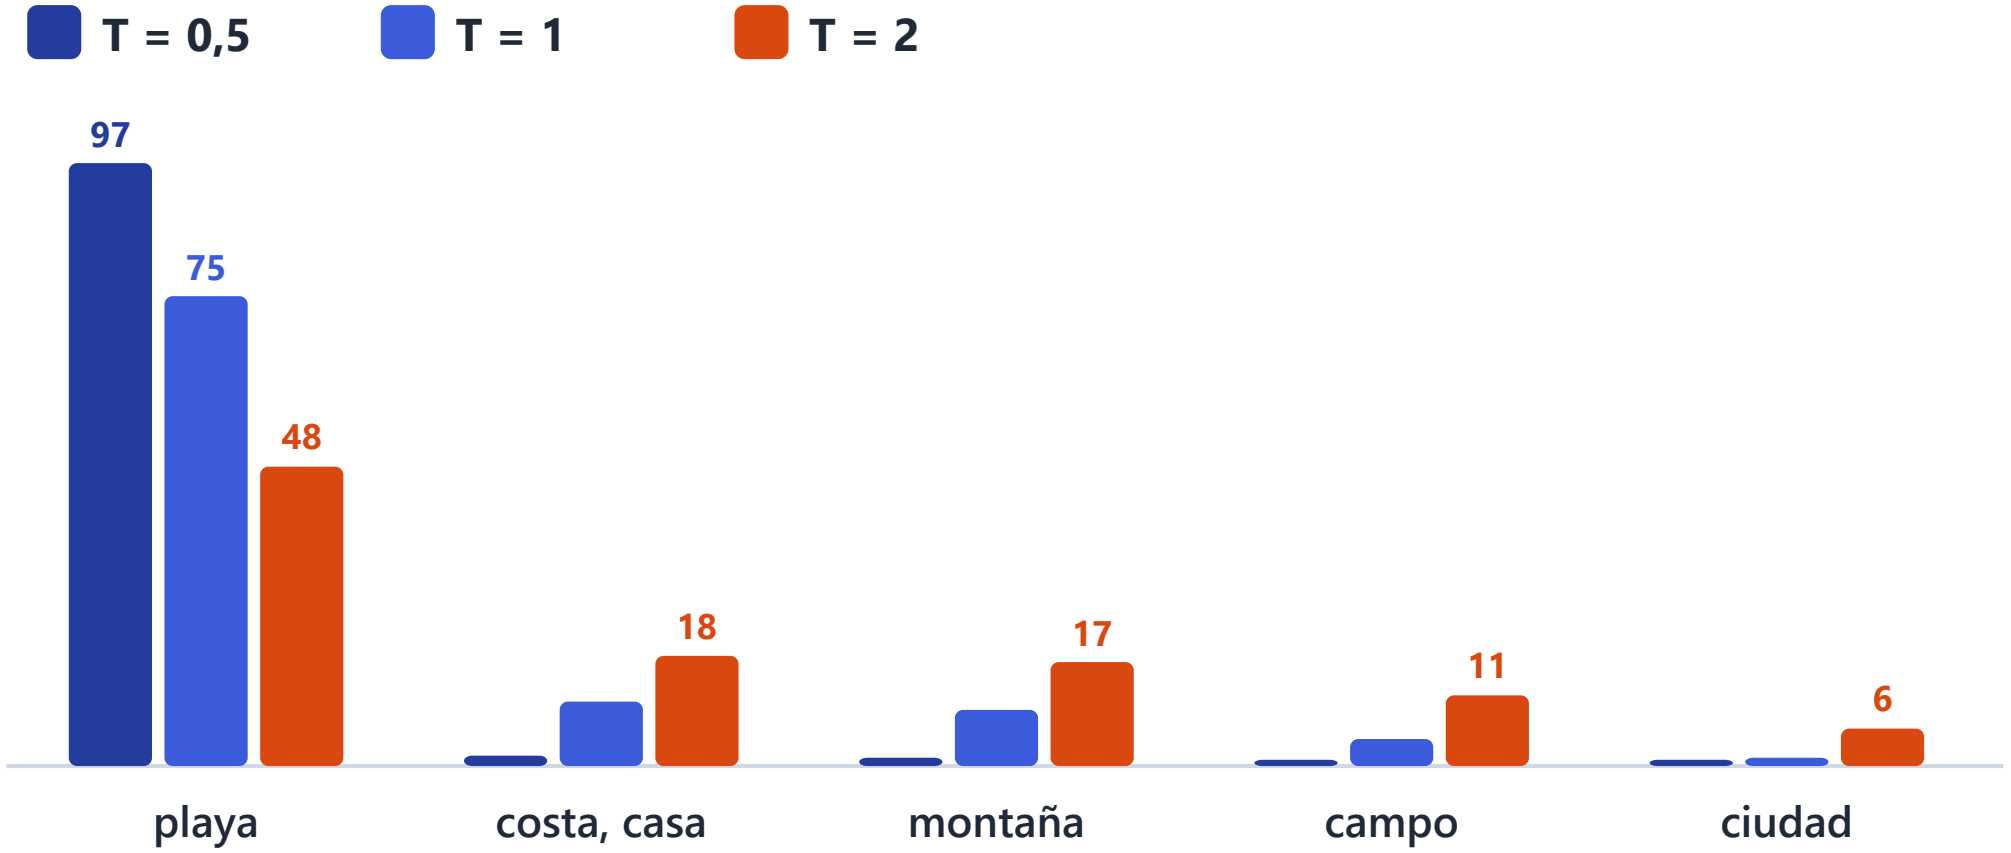
### 3. Sortear

una palabra con esas probabilidades

**Sortear: un dado cargado. Con playa al 75 %, sale playa unas 75 de cada 100 veces.**

**Cambia la variedad, no la verdad.**

# La temperatura estira o aplana lo mismo




Mismas opciones, otro reparto.

# Gemini 3.5 ignora la temperatura

respuestas distintas de 5, por corrida

**Gemini 3.5** **T = 0**



Café Pocitos, MonteCafé, Montevideana…

**Gemini 3.5** **T = 1**



**Gemini 3.1** **T = 0**



«Montevideo Mío» las 5 veces, en las 3 corridas

**Gemini 3.1** **T = 1**

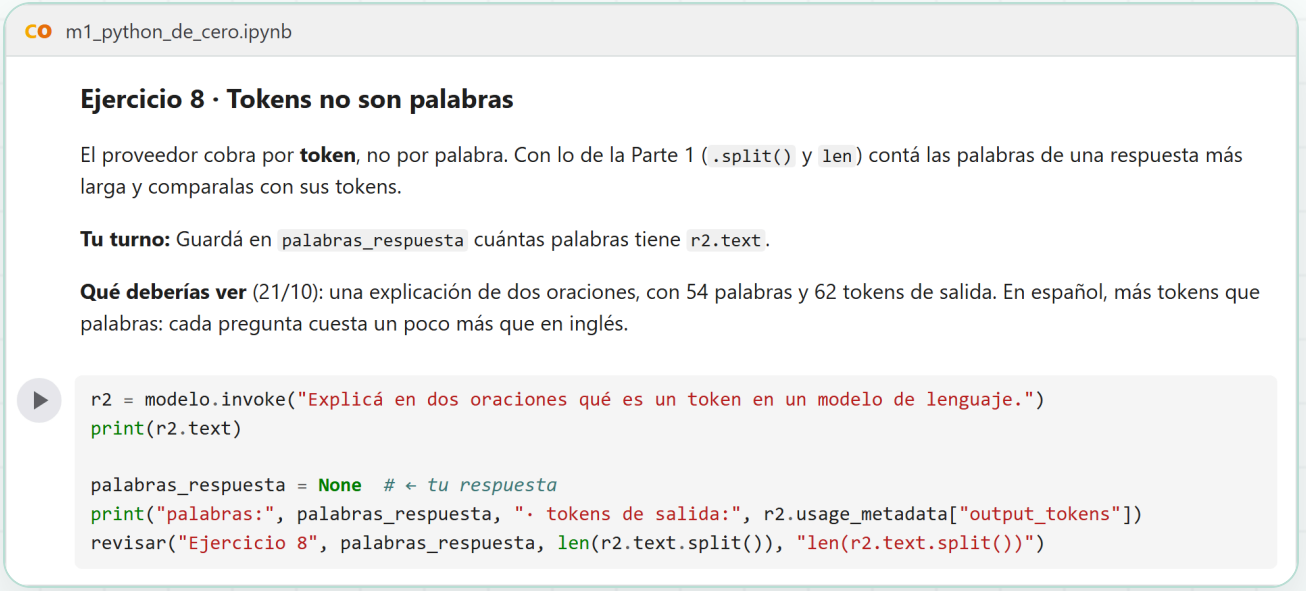


Café del Sur, Montevideo Místico…

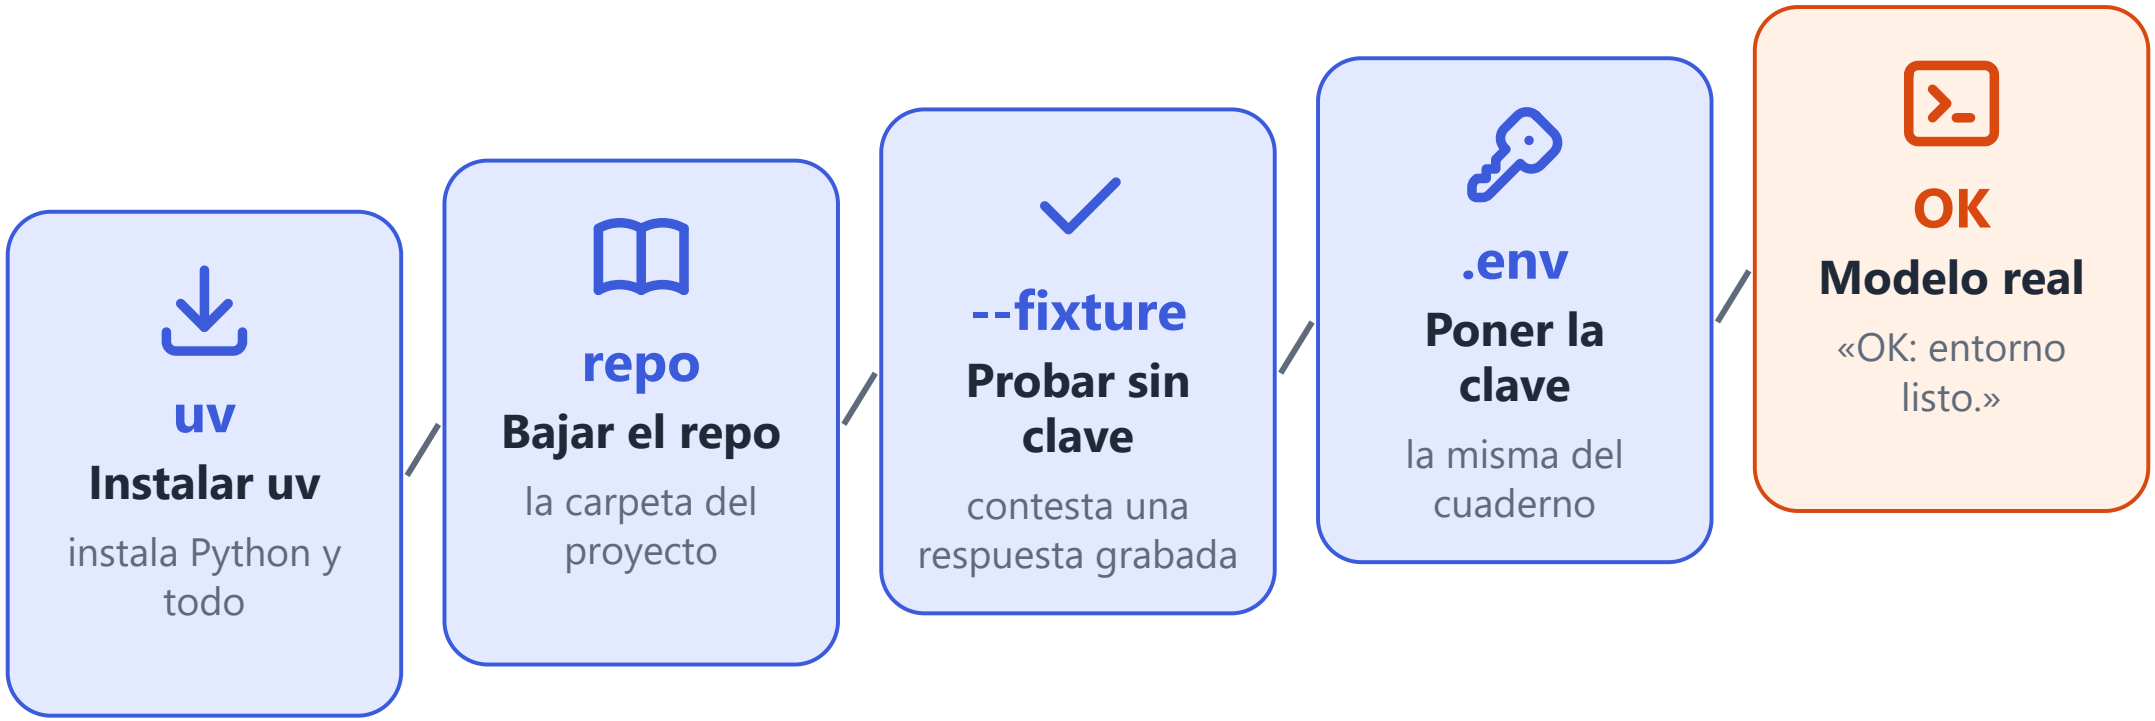
# Cuaderno, parte 3: tokens, temperatura y JSON

**Objetivo:** ver de cerca tokens y temperatura en un LLM real.

- Ejercicios 8 y 9, 15 min: tokens contra palabras y temperatura.
- El 10 (JSON), en casa.



# Entorno guiado: lo mismo, desde tu computadora




Si check_setup.py dice «OK: entorno listo.», estás arriba.

Paso a paso: «Antes de la clase 1», en el aula virtual.

# El modelo no ve palabras: ve tokens

**Castellano: 11 tokens**

`Los` `·estudiantes` `·descon` `fi` `aban` `·de` `·las` `·respuestas` `·del` `·modelo` `.`

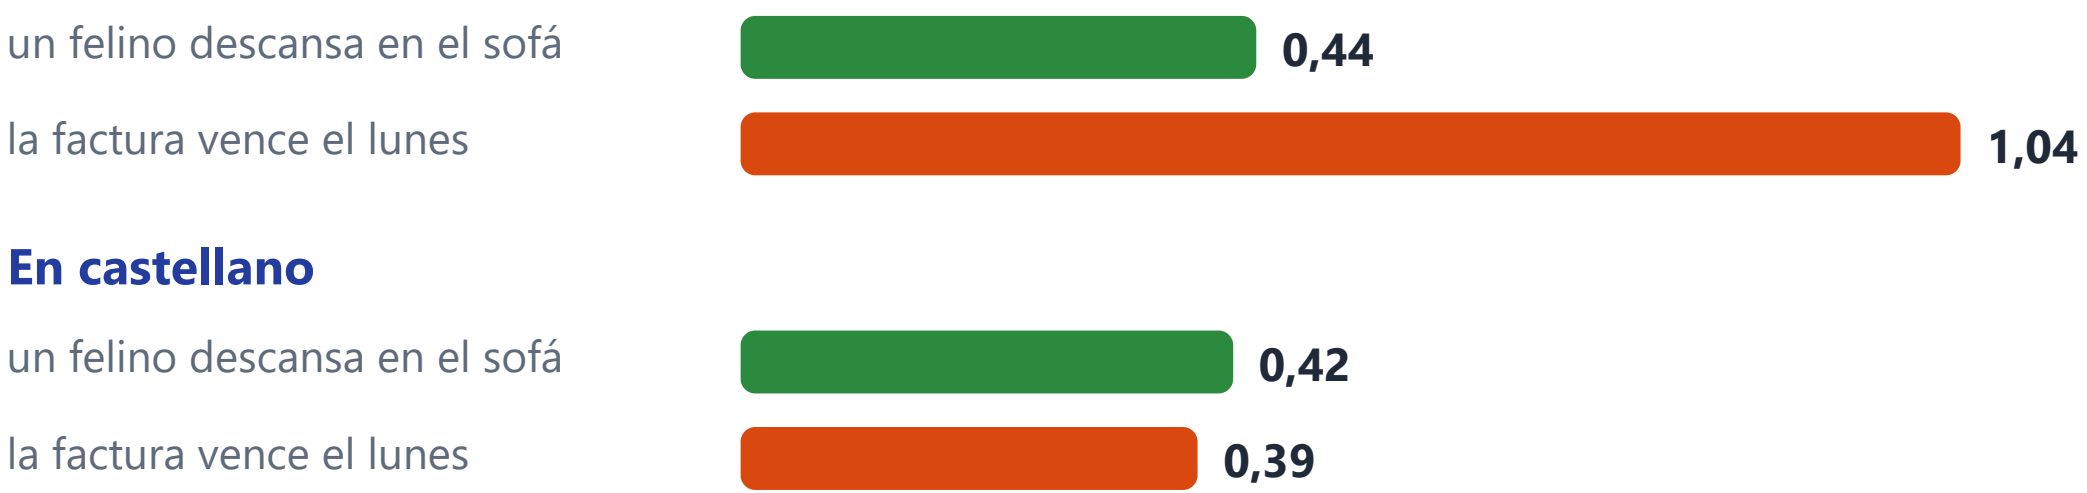
**Inglés: 9 tokens**

`The` `·students` `·distr` `usted` `·the` `·model` `'s` `·answers` `.`

**Token** = un pedazo de palabra. Se paga por token.

# Lo parecido queda cerca, si el modelo sabe el idioma

**Distancia desde «el gato duerme en el sillón» (0 = igual)**




En castellano, la factura queda tan cerca como el felino: este modelo no separa.

Texto = vector (**embedding**).

# La atención decide qué palabras importan

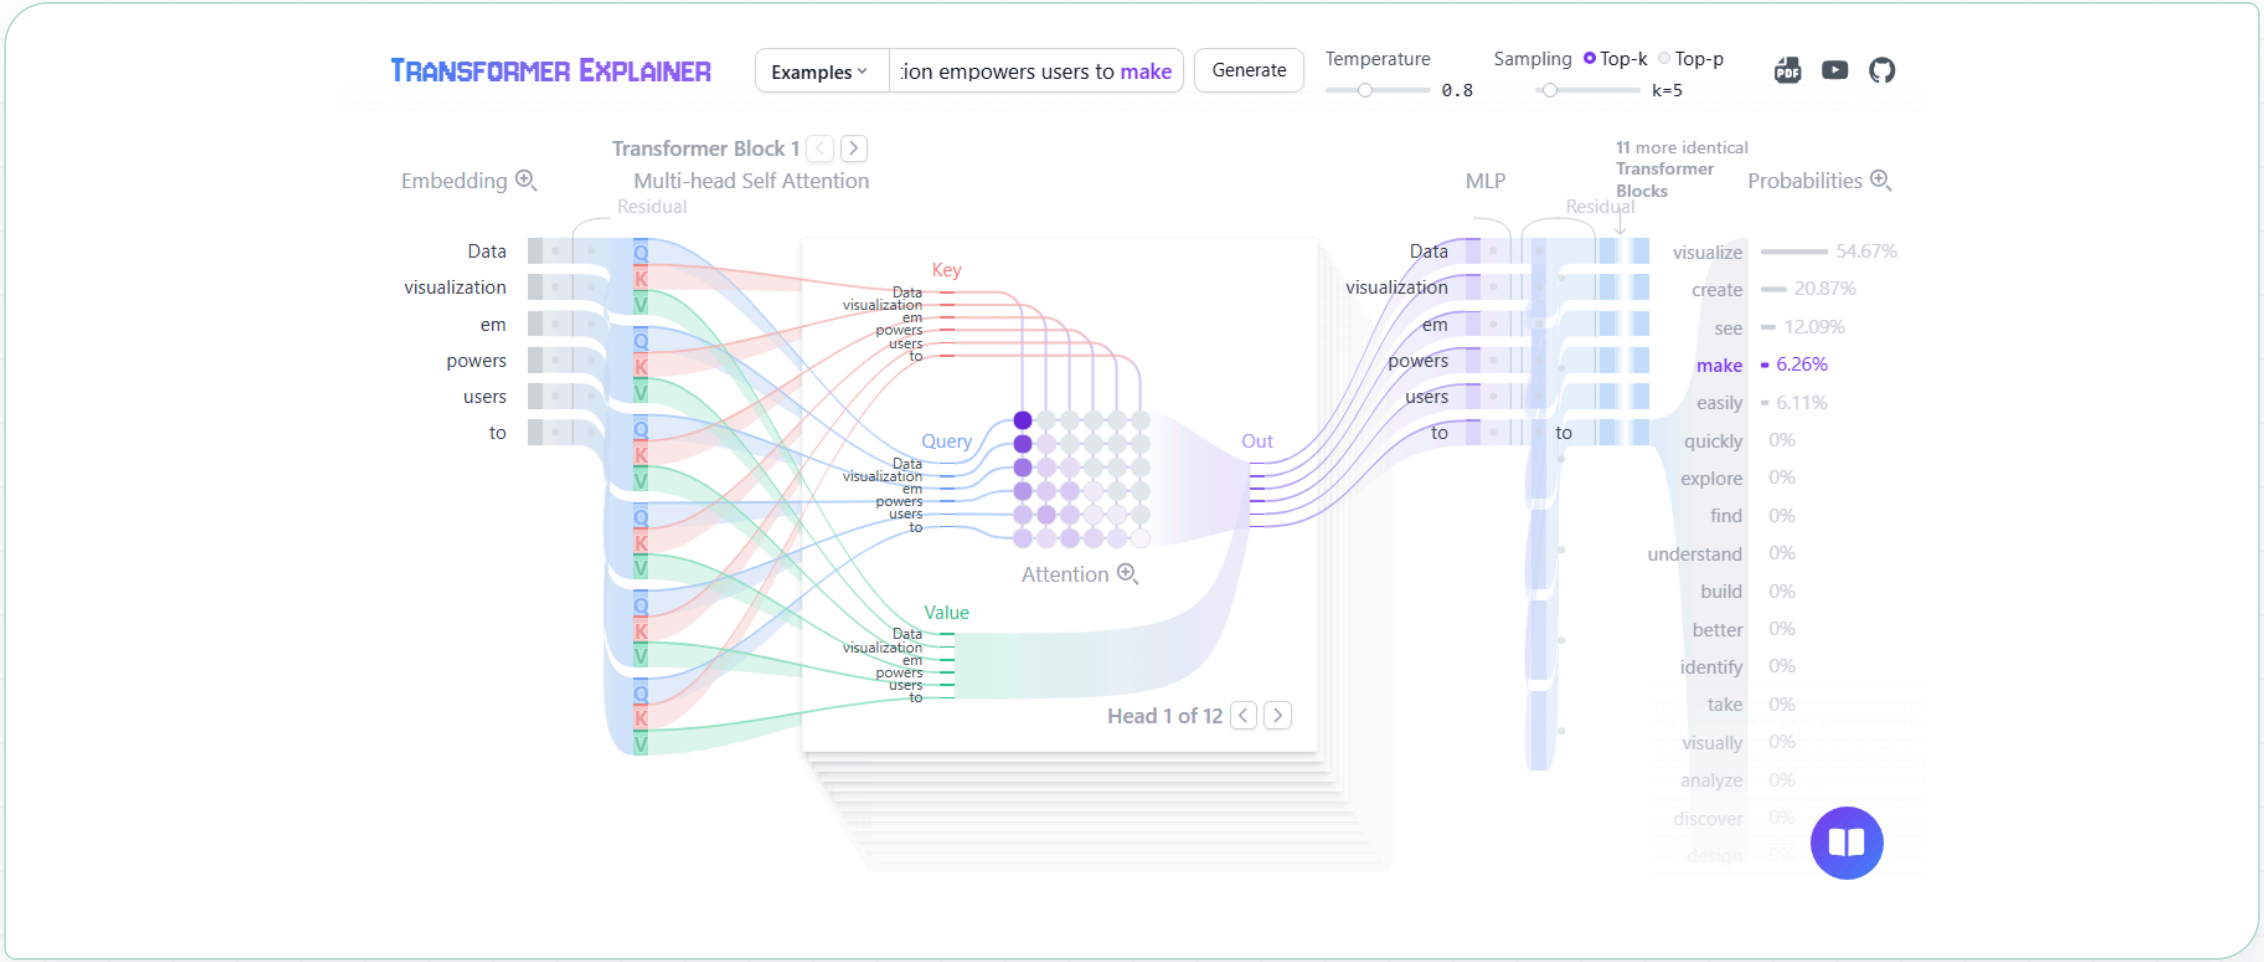
**Texto**
**«Me senté en el banco de la plaza y estaba…»**

→

**Tiene que pesar más**
**«plaza» y «senté»: es un asiento, no un banco de dinero**

- Lo agregó el Transformer (2017).
- Cómo se ve por dentro, en la próxima.

# GPT-2 por dentro: sorteó «make», con 6 %




Sorteó: el 6 % sale 1 de 16. Transformer Explainer

# Predice lo probable, no lo verdadero




Por eso inventa con seguridad, sobre todo nombres, fechas, cifras y citas.

# Le preguntamos por un libro que no existe

**Gemini 3.5 Flash-Lite**

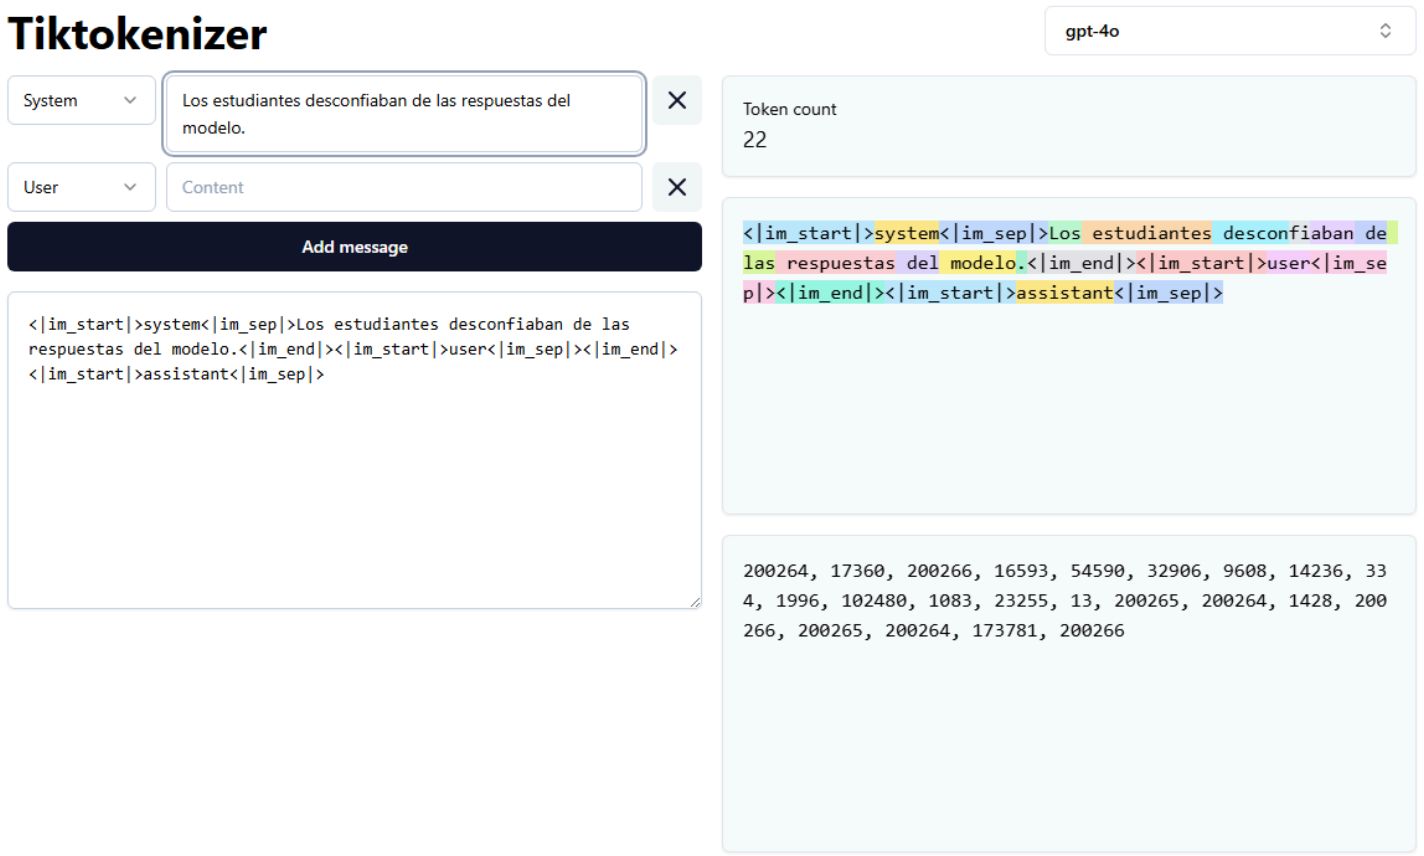
Resumí en dos frases el libro «El álgebra de los ríos» de Mario Benedetti.

«El álgebra de los ríos», de Mario Benedetti, es un poemario de tintes melancólicos donde el autor reflexiona sobre el paso inexorable del tiempo, la memoria y la soledad…

**Ese libro no existe**

Predijo lo probable, con seguridad.

# En Tiktokenizer: 11 tokens de la frase y 11 del chat




Probalo: Tiktokenizer

Paso 5 de 5: Probar y explicar

# El lab: modelo, prompt, temperatura y repeticiones

CO m1_laboratorio.ipynb

### 2 · Perillas

- `MODELO_T`: la temperatura la usa Gemini 3.1 Flash-Lite; el 3.5 la ignora.
- Tope: 20 llamadas por persona (`TOPE`). Cada repetición es una llamada.

```
MODELO_T = "google_genai:gemini-3.1-flash-lite"
PROMPT = "Inventá un nombre para una cafetería en Montevideo. Respondé solo el nombre."
TEMPERATURA = 0.0
REPETICIONES = 5
TOPE = 20
```

### 3 · Experimento 1: temperatura

**Predecí antes:** con 0, ¿cuántas distintas sobre 5? Corré, anotá, cambiá `TEMPERATURA` a 1 en las perillas y corré de nuevo esa celda y la de `correr(...)`.

En ucu-la, práctica M1 → «Open in Colab».

# Laboratorio: cambiá una cosa y mirá

**Objetivo:** cambiar una sola cosa y explicar lo que pasó. Elegí un experimento (práctica M1). ¿Qué va a pasar? Escribilo **antes**, en «Tu predicción» del lab.

**Primer control · 10–15 min:** 3 respuestas con tokens.



# Cuatro propiedades explican qué falla

## 1 Predice el próximo token

escribe lo probable, pedazo a pedazo

Le va bien
**Resumir**

Le cuesta
**Datos precisos**

## 2 Sabe lo que vio al entrenar

conocimiento: nada de después ni de tu empresa

Le va bien
**Lo frecuente**

Le cuesta
**Lo reciente o local**

## 3 Lee lo que le pasás

memoria de trabajo: tu pedido, hasta un máximo

Le va bien
**Texto corto**

Le cuesta
**Un dato en el medio de uno largo**

## 4 Sigue instrucciones

lo entrenaron con pedidos y respuestas

Le va bien
**Formato**

Le cuesta
**Cadenas largas de pasos**

Cuando algo falla, preguntate cuál de las cuatro fue.

# Cerrados por API, abiertos en tu máquina

| | Cerrados, por API | Abiertos, en tu máquina |
|---|---|---|
| Dónde corre | En el proveedor | En tu computadora |
| Tus datos | Salen | Quedan |
| Qué se publica | Ni pesos ni datos | Los pesos, casi nunca los datos |

# Muchas empresas hacen modelos de lenguaje

- **Gemini (Google)**
- **GPT (OpenAI)**
- **Claude (Anthropic)**
- **Llama (Meta)**
- **Mistral**
- **Qwen (Alibaba)**
- **DeepSeek**
- **Ollama, en tu máquina**

Usamos Gemini por el plan gratis. Lo que aprendés sirve para todos.

# Repaso: hoy te llevás tres ideas



**Predice**

elige el próximo token
por su probabilidad



**Temperatura**

cambia la variedad, no
la verdad



**Inventa**

dice lo probable.
Chequeá nombres, fechas
y cifras.

# Antes de irte: ¿qué te sorprendió?

¿Qué viste que contradijo tu predicción? ¿Qué lo explicaría?

Anotá tu **confianza (1 a 4)** y el tema que pensás usar.

El miércoles no hay que leer nada antes: arrancamos con prompts.