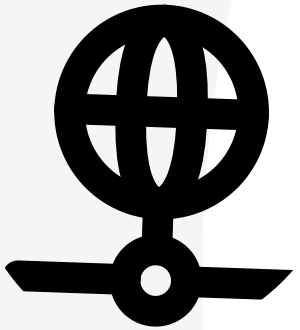
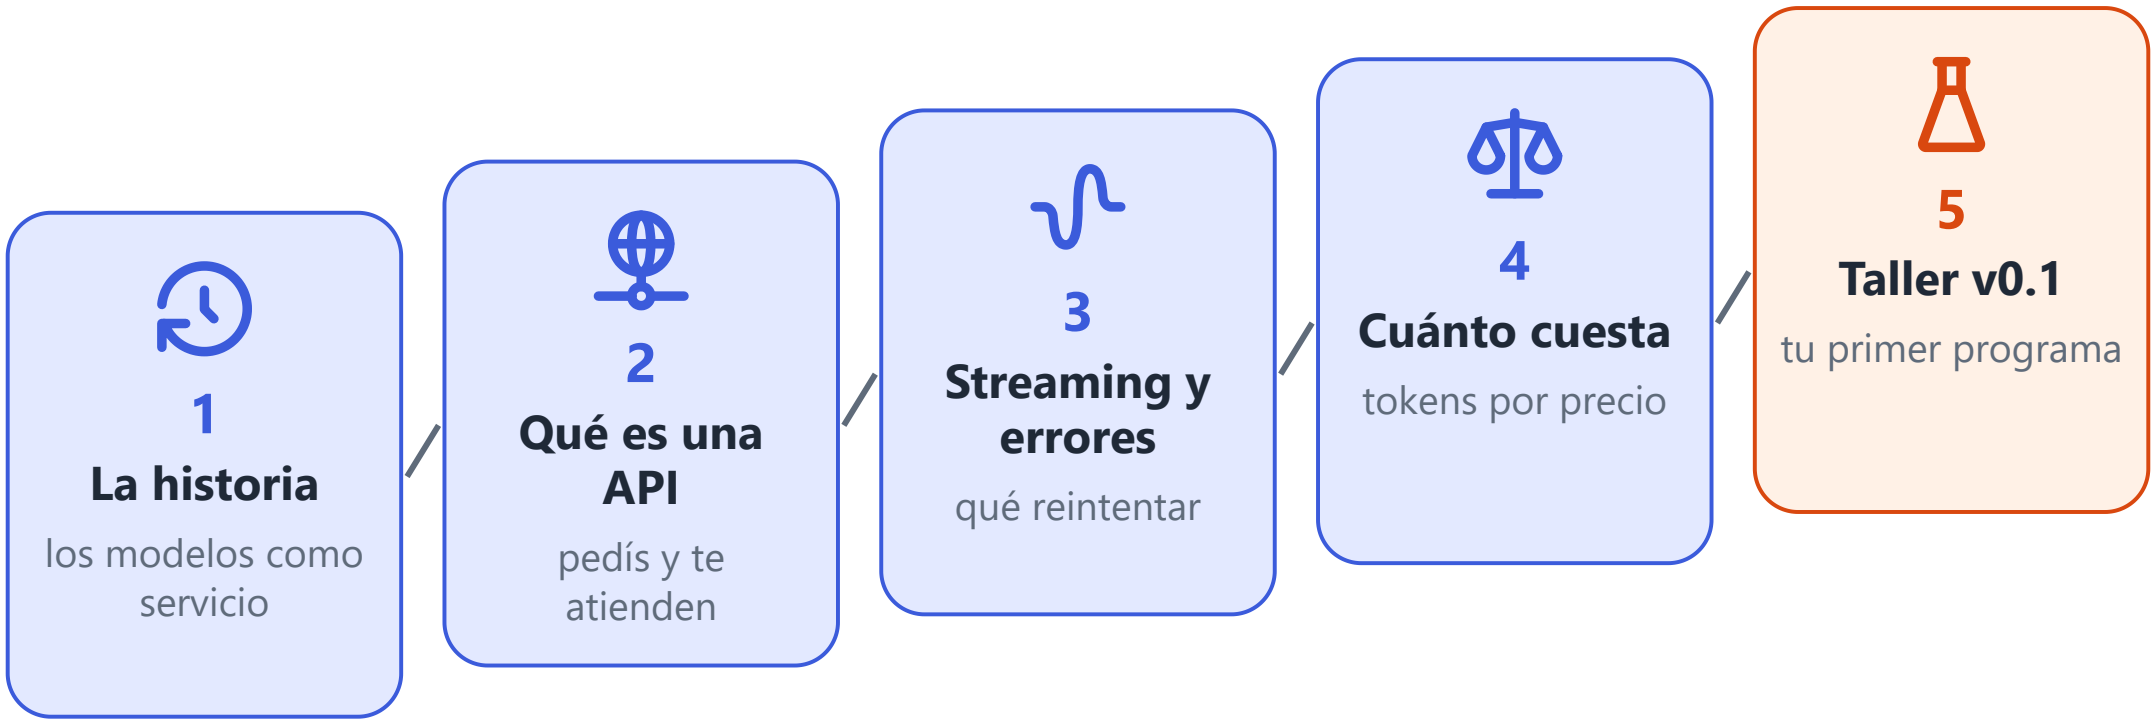
APIs

M3: APIs, v0.1



Hoy: el recorrido

Del chat a un programa que mide



Venís de pedirle datos con un molde. Ahora, desde tu propio programa.

Sin mirar: ¿qué no detectó tu molde?

?

Tu error de M2

uno que el molde dejó pasar: el dato entró, pero estaba mal

Escribilo en una línea: lo vamos a necesitar al final.

¿Qué error dejó pasar tu molde?

Lo que el molde suele dejar pasar



1,25 por 1.250

una cifra mal leída que igual es un número



999

la orden escondida del texto 7: también es un número válido

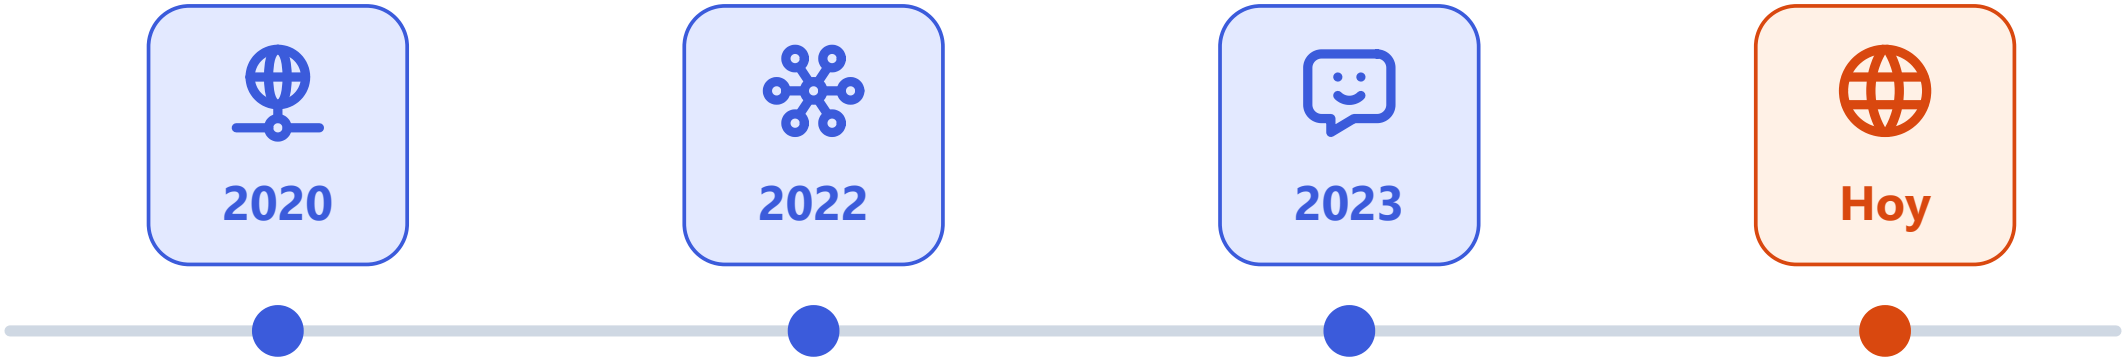


«Las Acacias»

una entidad incompleta: forma bien, dato mal

El molde controla la forma, no la verdad.

Los modelos se usan como un servicio



Por eso tu código cambia poco si cambiás de proveedor.

Una API es un mostrador: pedís y te atienden

Pedís

modelo, mensajes y tope,
con tu clave (dice quién sos)

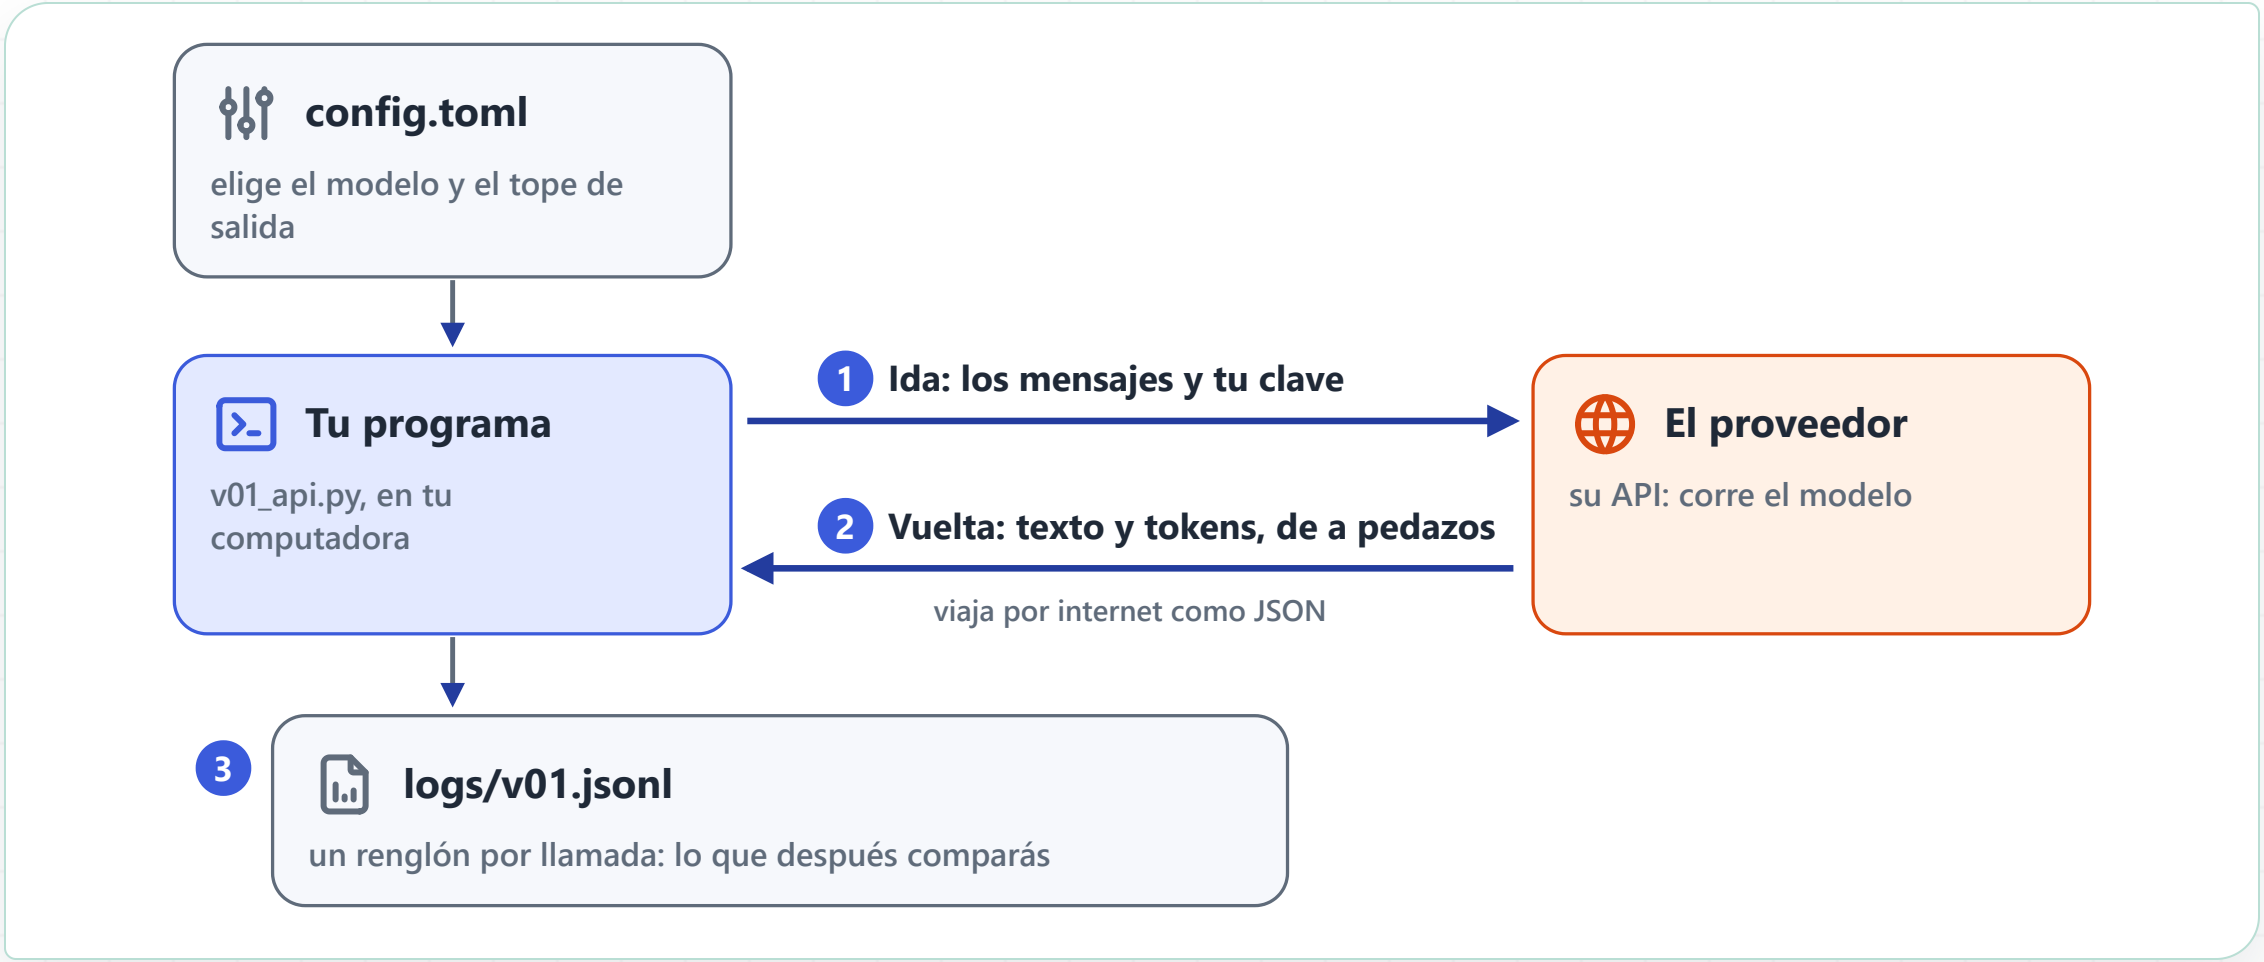
Te atienden

con el texto y la cuenta:
cuántos tokens usó

Donde falla: el mostrador no te recuerda. Cada pedido empieza de cero.

La slide que sigue muestra la llamada de verdad.

Una llamada es un pedido que viaja y vuelve



Va el pedido con tu clave; vuelven texto y tokens.

Lo que viaja es una lista de mensajes con rol

```
[
 {"role": "system",
   "content": "Sos un asistente para estudiantes…"},
 {"role": "user",
   "content": "¿Qué es un token en un LLM?"}
]
```

system: las reglas de siempre

user: la pregunta de ahora

Viaja la lista entera en cada llamada.

Cada mensaje es un par (rol, texto)

m3_v01_api.ipynb

```python
def preguntar(modelo, pregunta):
    inicio, respuesta = time.perf_counter(), None
    for pedazo in modelo.stream([("system", SISTEMA), ("human", pregunta)]):

    return respuesta.text, respuesta.usage_metadata, round(time.perf_counter() - inicio, 2)
```

Vuelven texto, tokens y segundos.

Lo que vuelve: el texto y la cuenta de tokens

Ollama, qwen3.5:2b

Sistema: Sos un asistente para estudiantes. Respondé en español, en dos frases…

¿Qué es un token en un LLM?

Un token es la unidad mínima de texto que procesa un modelo de lenguaje artificial, ya sea una palabra completa o una parte de ella…

Vuelve también:

45 de entrada
con el sistema incluido

52 de salida

97 en total

Se pagan.

El modelo no recuerda: la historia la mandás vos

A · solo la pregunta

¿Cómo me llamo?

No tengo nombre propio, soy una inteligencia artificial generada por humanos. ¿En qué puedo ayudarte hoy?

B · con la historia

Me llamo Ana.

¡Hola, Ana!

¿Cómo me llamo?

Tu nombre es Ana, y yo soy tu asistente virtual.

Mismo modelo y sistema.

Tres palabras cambiaron la respuesta correcta

A · ambigua

¿Qué es una alucinación?

Una alucinación es una percepción falsa que ocurre cuando el cerebro interpreta estímulos no reales como si fueran verdaderos.

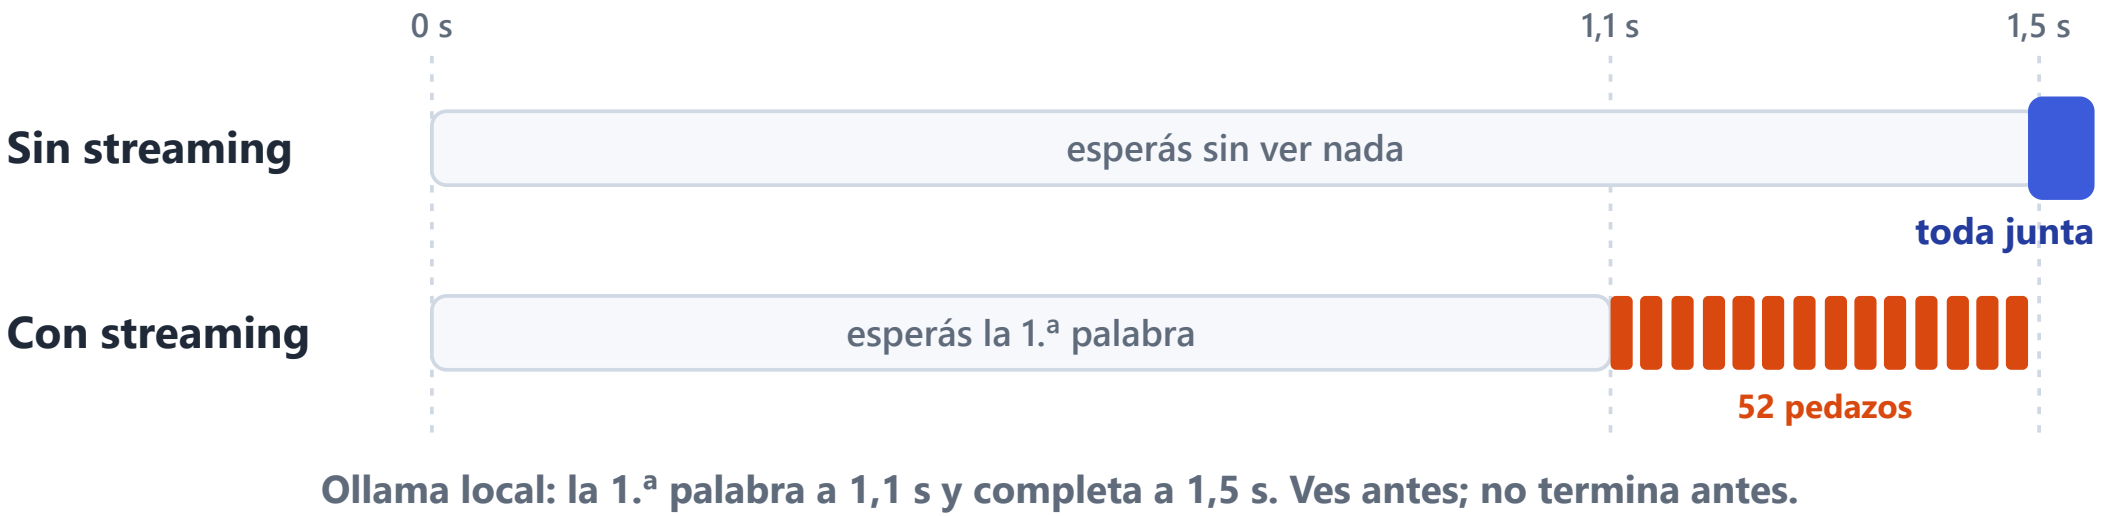
B · con «en un LLM»

¿Qué es una alucinación en un LLM?

Una alucinación en un modelo de lenguaje artificial ocurre cuando el sistema genera información falsa o inventada…

Medí con preguntas bien escritas.

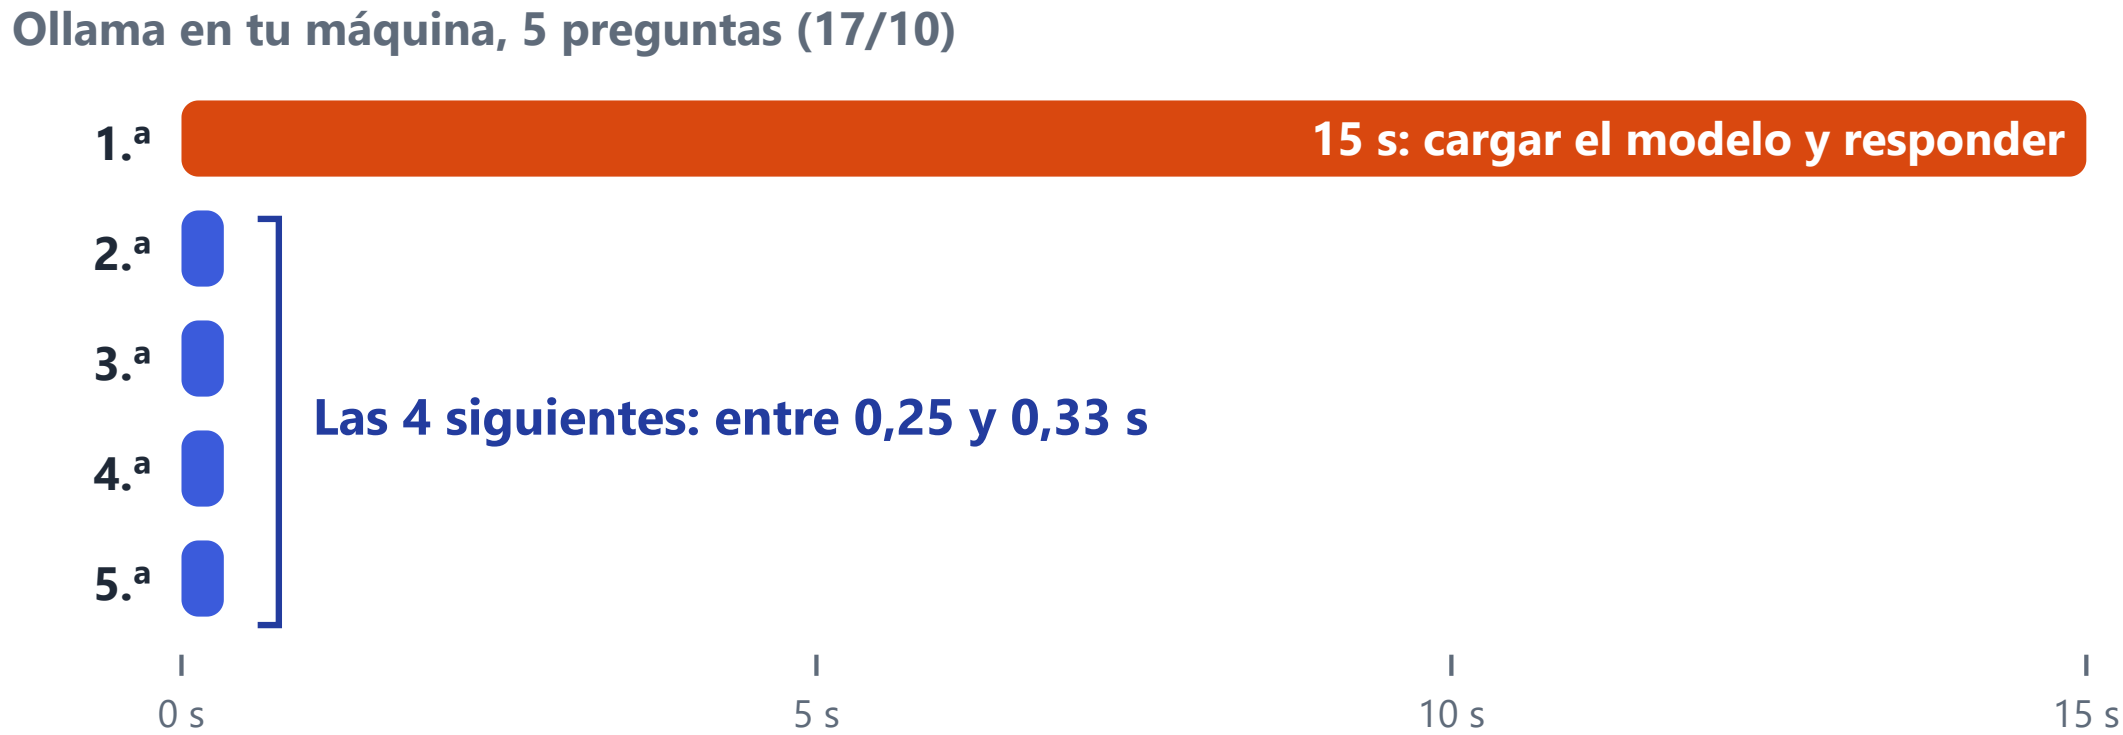
El streaming muestra antes, no termina antes



Ollama local: la 1.ª palabra a 1,1 s y completa a 1,5 s. Ves antes; no termina antes.

Streaming = la respuesta llega en pedazos.

En tu máquina, la primera llamada carga el modelo



Al medir, descartá la primera.

El streaming junta pedazos para medir

```
def preguntar(modelo, pregunta):
    inicio, respuesta = time.perf_counter(), None
    for pedazo in modelo.stream(
            [("system", SISTEMA), ("human", pregunta)]):
        print(pedazo.text, end="", flush=True)
        respuesta = pedazo if respuesta is None else respuesta + pedazo
    print()
    return respuesta.text, respuesta.usage_metadata, \
        round(time.perf_counter() - inicio, 2)
```

Arranca el reloj

Los pedazos llegan de a uno

Los suma: al final queda la respuesta entera

Vuelven texto, tokens y segundos

Cada pedazo se muestra apenas llega.

Con Ollama, cada pedazo es más o menos un token

Ollama: los primeros pedazos

`Un` `·token` `·es` `·la` `·unidad` `·mínima` …

52 pedazos · 1.ª palabra a 1,1 s · completa a 1,5 s

Gemini: 5 o 6 pedazos por respuesta

`Un` | una frase entera | una frase entera | una frase entera | una frase entera

El tamaño de cada pedazo lo decide el proveedor.

El tope de salida corta la respuesta

Con un tope de 12 tokens de salida

¿Para qué sirve la temperatura en un modelo de lenguaje?

La temperatura controla el equilibrio entre la precisión y la creatividad

sin punto final

tokens de entrada: 47

tokens de salida: 12

motivo de fin:

`length (se cortó)`

Es `max_salida` de `config.toml`.

Reintentá lo pasajero, no lo que está mal

Reintentar

pasajero: esperá y otra vez

- `429` demasiados pedidos
- `timeout` tardó demasiado
- `5xx` falla del servidor

Corregir

está mal: reintentar no sirve

- `400` pedido mal armado
- `401` clave inválida (Gemini: 400)
- `404` modelo inexistente

La slide que sigue muestra cómo decide el programa.

Un 429 por día no se arregla reintentando

```
429 RESOURCE_EXHAUSTED.
You exceeded your current quota …
Quota exceeded for metric:
  generate_content_free_tier_requests,
  limit: 500, model: gemini-3.5-flash-lite
Please retry in 7h32m8s.
```

— **Cuota gratis**

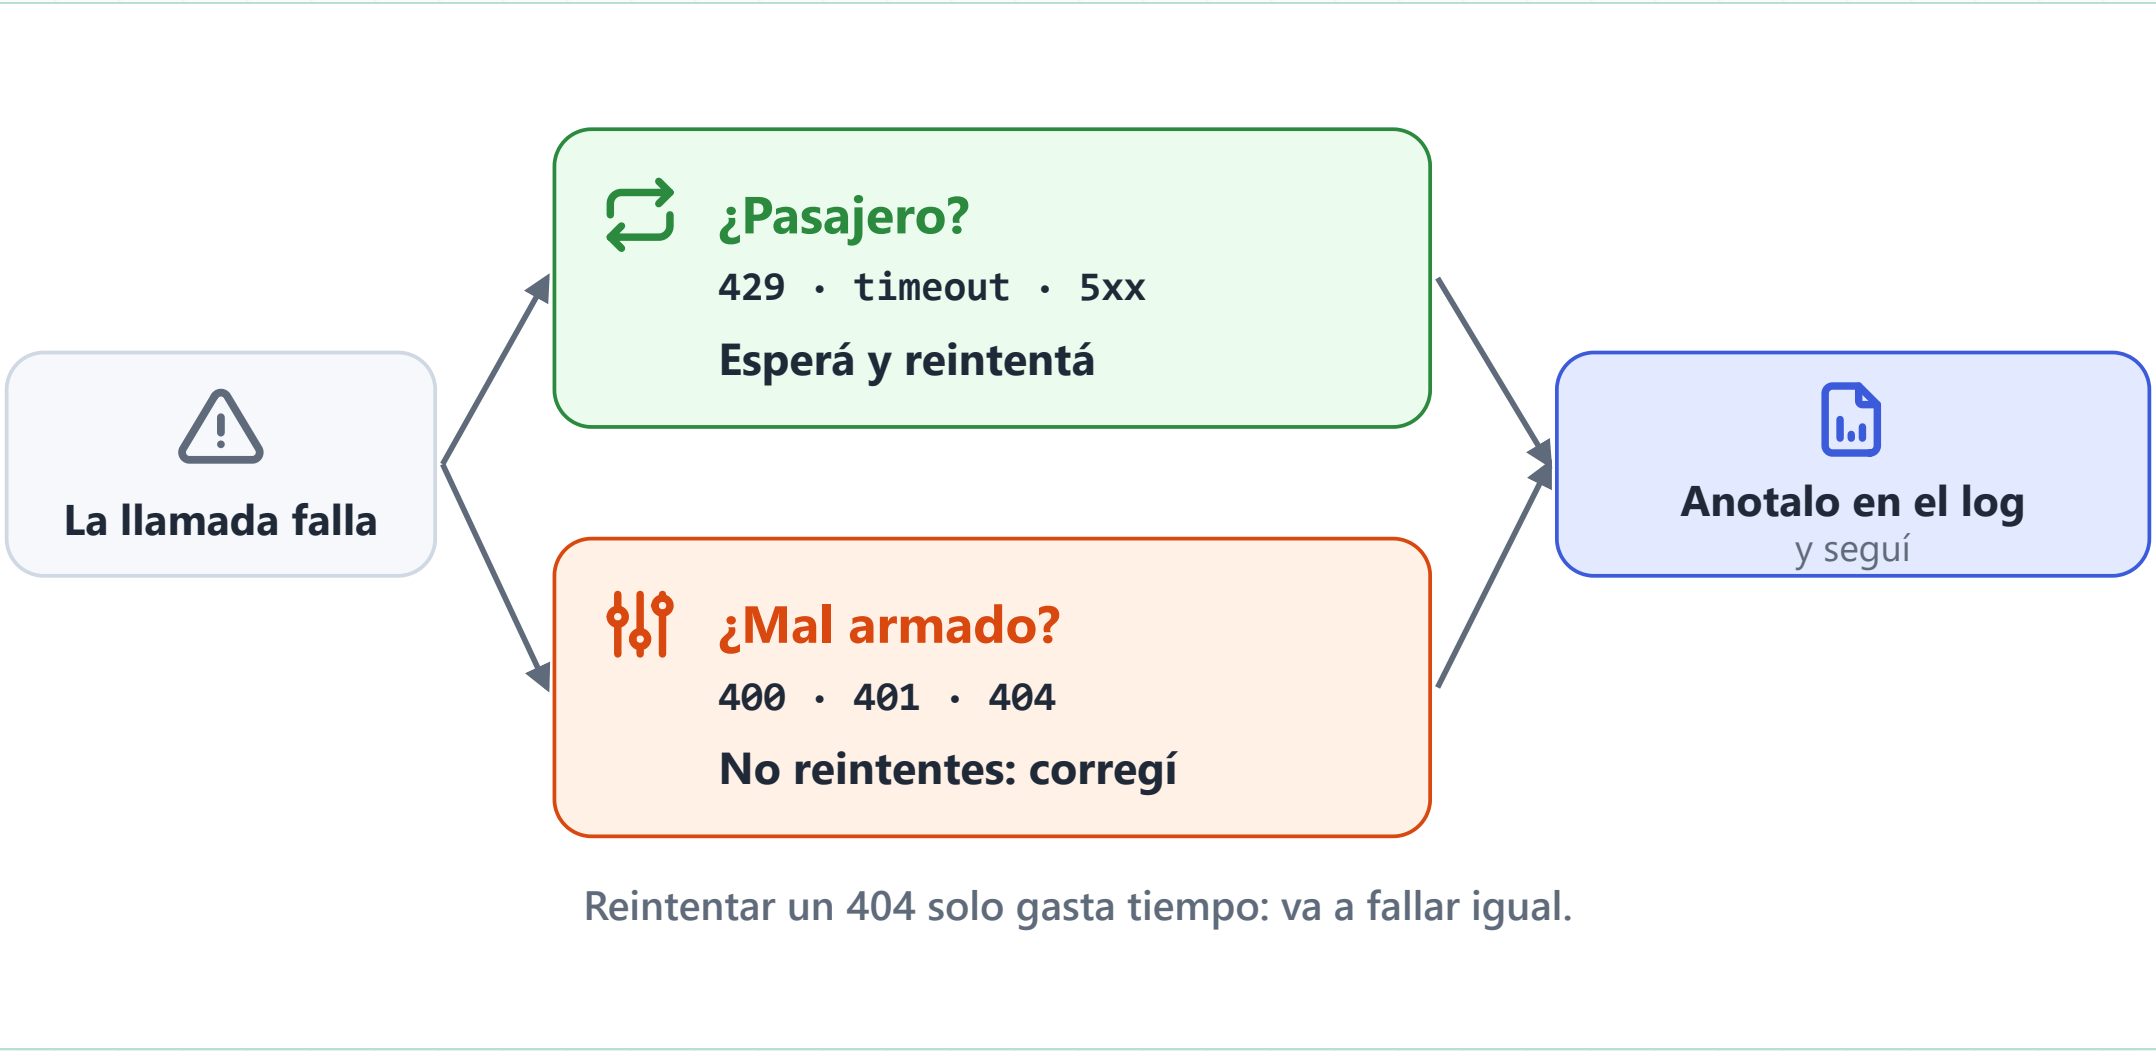
— **500 pedidos por día y por modelo**

— **Pide esperar horas: es la cuota del día**

No reintentes: esperá a mañana o cambiá de modelo.

¿Pide esperar horas o dice «PerDay»? No reintentes.

Ante un error, decidís si esperar o anotar



Reintentar un 404 solo gasta tiempo: va a fallar igual.

Reintentar: otra vez, con una espera

```
for intento in range(1, REINTENTOS + 1):
    try:
        texto, uso, segundos = preguntar(...)
        registro.append({...})
        break
    except Exception as error:
        if intento < REINTENTOS:
            time.sleep(2 * intento)
        else:
            registro.append({"error": ...})
```

- Hasta REINTENTOS veces
- Salió: no reintenta
- 429, 503, red: falló esta vez
- Espera 2 s, 4 s… antes de otra vez
- Se acabaron: lo anota y sigue

Si sigue fallando, se anota y sigue.

El error a propósito queda anotado

m3_v01_api.ipynb

```python
try:
    init_chat_model("google_genai:modelo-que-no-existe").invoke("hola")
except Exception as error:
    registro.append({"modelo": "google_genai:modelo-que-no-existe", "error": type(error).__name__})
    print("Error controlado:", type(error).__name__)
```

Un 404 no se reintenta.

Otro proveedor: otros tokens, otro error

	Ollama	Gemini 3.5 Flash-Lite
Tokens de entrada	45	28
Tiempo	15 s la 1.ª, 0,3 s luego	1 s, a veces 20 s
Error	`ResponseError`	`GoogleModelNotFoundError`

Otro tokenizador: tokens no comparables.

Predecí qué pasa en tres llamadas

1. **Predecí** y anotá las tres respuestas.
2. **Mirá** las tres corridas en vivo: `memoria`, `pedazos` y `tope`.
3. **Compará** con tu predicción.



`memoria` ?

¿Recuerda tu nombre sin la historia?



`pedazos` ?

Corré 2 veces: ¿cuándo llega la 1.ª palabra?



`tope` ?

¿Con qué motivo de fin termina?

Cada pregunta deja un renglón en el log

```
{"modelo": "ollama:qwen3.5:2b",
  "sistema": "Sos un asistente…",
  "pregunta": "¿Qué es una alucinación…?",
  "respuesta": "Una alucinación en…",
  "latencia_s": 0.32,
  "tokens_entrada": 47,
  "tokens_salida": 30}
```

— **Con qué modelo**

— **Lo que devuelve tu responder()**

— **Cuánto tardó, en segundos**

— **Tokens que entran y salen: de acá sale el costo**

Cada corrida agrega un renglón; no borra.

`logs/v01.jsonl` : un diccionario por renglón.

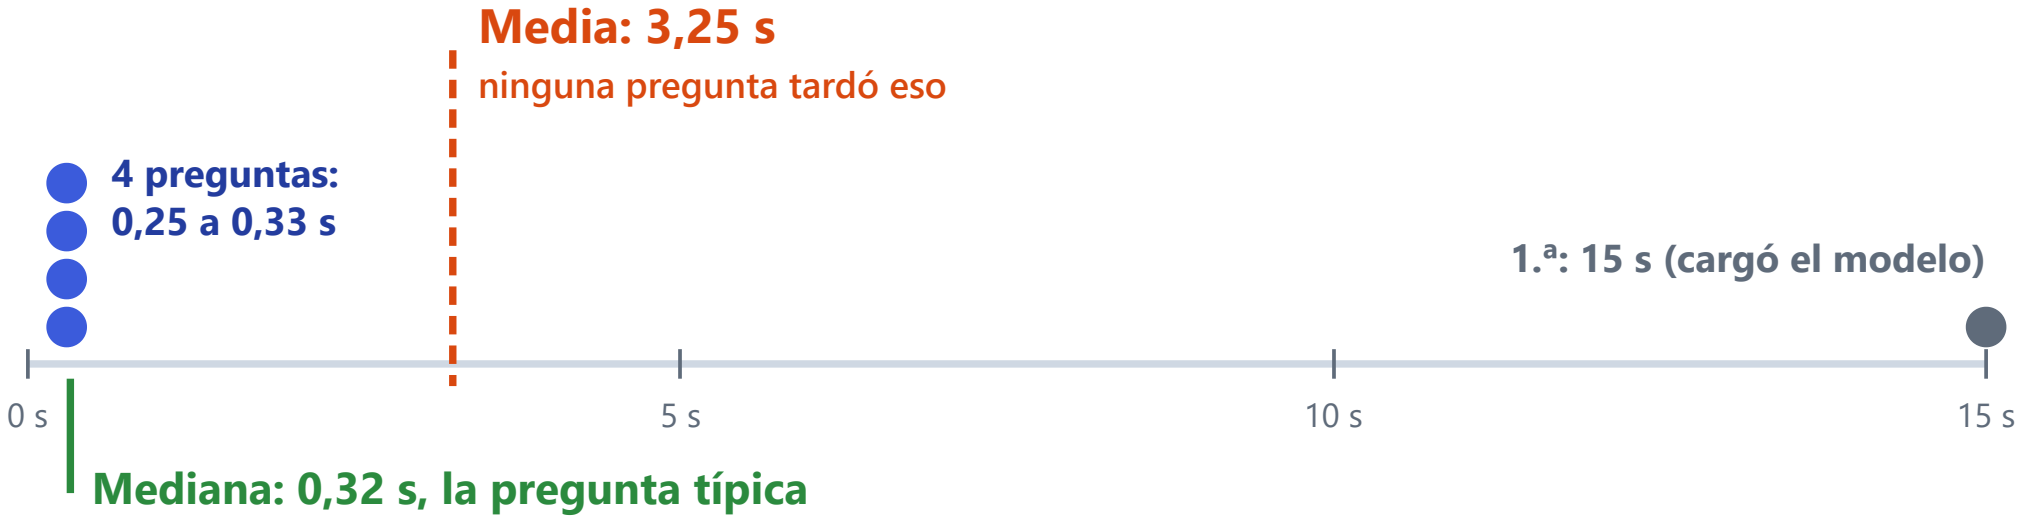
Con pandas, el registro se vuelve tabla

m3_v01_api.ipynb

```
tabla = pd.DataFrame(registro)
bien = tabla[tabla.get("error").isna()] if "error" in tabla else tabla
print(bien.groupby("modelo")[["entrada", "salida", "latencia_s"]].mean().round(1))
print(bien.groupby("modelo")[["latencia_s"]].median())  # la mediana de la latencia va en tu tabla
```

Una fila por configuración. Más en pandas.

La media engaña: una llamada lenta la arrastra



Ollama, 17/10: la primera tardó 15 s porque cargó el modelo.

¿Qué pesa más en el costo de tu consulta?

Costo = tokens de entrada × su precio
+ tokens de salida × su precio

Entrada

500 tokens

US$ 0,10 por millón

Salida

200 tokens

US$ 0,40 por millón

Total del ejemplo: US$ 0,00013. ¿Qué pesa más: la entrada o la salida?

¿La entrada o la salida?

La salida pesa más, aunque sean menos tokens



Con estos precios, cada token de salida cuesta 4 veces más. En Gemini 3.5 Flash-Lite (19/10), 8.

Mirá la salida: es la que más cuesta.

El costo sale de los tokens

```
PRECIO_ENTRADA = 0.30
PRECIO_SALIDA = 2.50
CONSULTAS_POR_DIA = 1000
por_pregunta = bien["entrada"].mean() * PRECIO_ENTRADA / 1_000_000 \
             + bien["salida"].mean() * PRECIO_SALIDA / 1_000_000
print(... por_pregunta * CONSULTAS_POR_DIA * 30 ...)
```

— **8 veces la de entrada**

— **tokens × precio ÷ millón**

— **por mes: US$ 3,75 (21/10)**

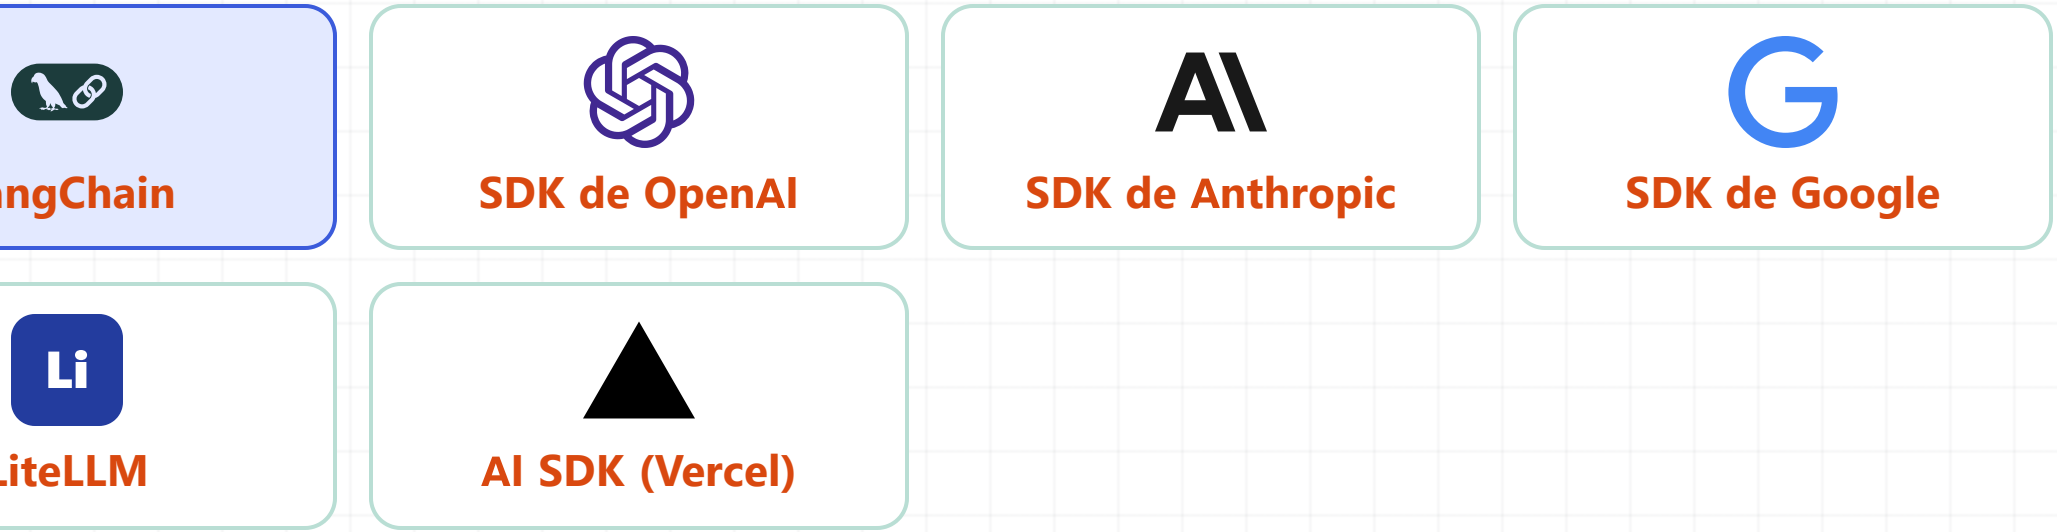
Medido el 21/10: US$ 3,75 por mes.

Cambiar de proveedor es una línea, casi

	Gemini 3.5 Flash-Lite	GPT-5.4 nano	Claude Haiku 5.5
Usa temperatura	✗	✗	✗
Usa herramientas	✓	✓ *	✓

* 12 de 12 en selección. «Casi»: cambia el modelo en config.toml y la clave en .env. Probado del 15 al 17/10.

LangChain no es la única forma de llamarlos



Cada proveedor tiene su **SDK**, su librería para llamarlo. LangChain los unifica: cambiar es una línea.

Taller: tus preguntas, dos configuraciones (25 min)

1. **Escribí** `responder(pregunta)` en `v01_api.py`.
2. **Probala** con 5 preguntas de tu tema.
3. **Dos configuraciones:** predecí y compará.

Práctica M3.

Primer control · 10–15 min: `logs/v01.jsonl` con tokens.

Repaso: hoy te llevás tres ideas



API

mandás mensajes con tu clave, vuelven texto y tokens



Errores

reintentá lo pasajero (429, 5xx), corregí lo que está mal



Costo

sale de los tokens, y la salida pesa más

Cerrá v0.1: commit y una decisión

Entrega de avance 1: `evidencia/v0.1.md`, *commit* y *push* hasta el mar 3/11, 23:59.

¿Qué error reintentás y cuál no? ¿Por qué?

Anotá tu **confianza (1 a 4)**. El mié, **Control de lectura 1** sobre las lecturas del Módulo 4 (en el aula virtual).