# RAG: medir

## M4: Medir, v0.2



Hoy: el recorrido

# De «parece que anda» a «lo medí»




Venís de armar el buscador. Ahora medís si mejora las respuestas.

Paso 1 de 4: Dónde quedamos

# Sin mirar: ¿dónde falló tu sistema?



?

**¿Recuperación?**

no encontró el fragmento



?

**¿Generación?**

lo encontró y respondió mal

**Elegí una pregunta de tu suite que no se resolvió. ¿Cómo lo sabés?**

¿Dónde falló: al buscar o al redactar?

# Posibles respuestas: buscar o redactar



## Recuperación

no llegó el fragmento con la respuesta



## Generación

llegó y respondió mal o inventó



## Cómo saberlo

rag.py con la misma pregunta muestra qué llegó, sin gastar

# Una suite es tu conjunto de prueba

### Está en los documentos

prueba que lo encuentre y lo use

### No está en ninguno

prueba que diga NO ENCONTRADO

### Intenta engañarlo

prueba que no se deje llevar

Siempre las mismas preguntas, como un test set.

# Cada número mide una parte distinta

| Métrica | Pregunta | Quién la calcula |
|---|---|---|
| hit | ¿Llegó el documento correcto? | `suite.py` |
| Abstención correcta | ¿Dijo NO ENCONTRADO solo cuando no estaba? | `suite.py` |
| Fidelidad (faithfulness) | ¿La respuesta sale de los fragmentos? | Ragas (opcional) |
| Correcta | ¿Es verdad? | Vos |

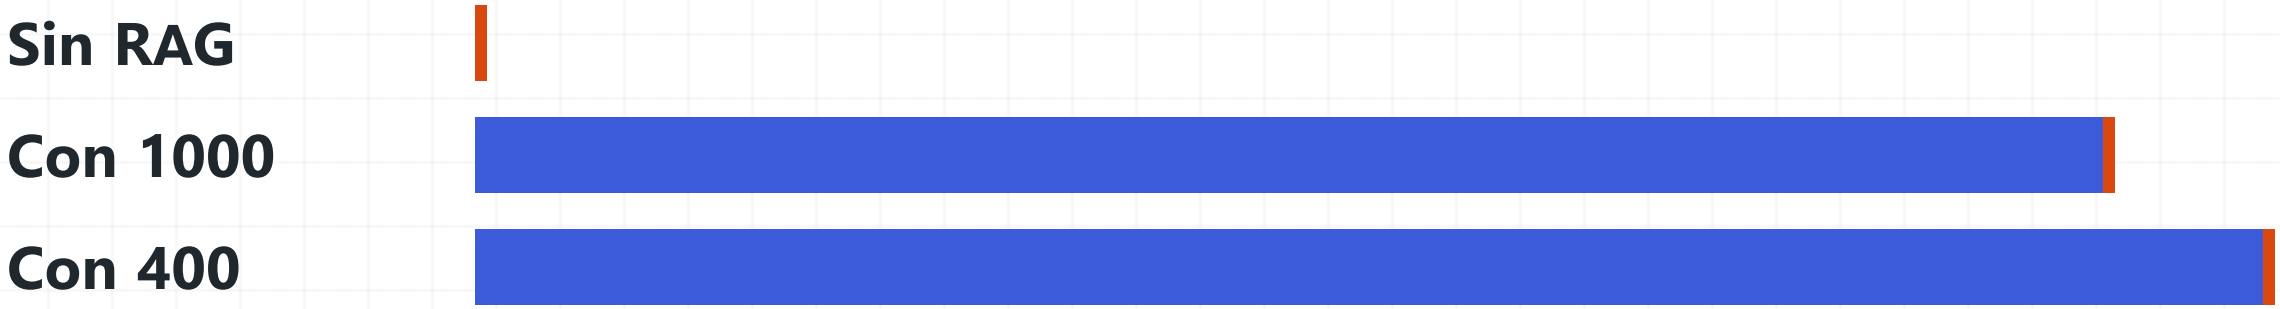
# Con RAG subió el hit, pero se abstuvo de más

```
uv run python suite.py v02_rag:sin_rag datos/m4_suite.jsonl --tag sin-rag
sin-rag: hit 0/11 · abstención correcta 11/13 · latencia mediana 0.8s
uv run python suite.py v02_rag:con_rag datos/m4_suite.jsonl --tag con-rag
con-rag: hit 10/11 · abstención correcta 8/13 · latencia mediana 1.5s

las 5 abstenciones de más: 1 sin el documento              → recuperación
                           3 con el documento, sin fragmento  → recuperación
                           1 con el fragmento (la 13)         → generación
```

- Gemini 3.5 Flash-Lite, 17/10.
- Abstención correcta: 11 sin RAG, pierde esas 5 y gana la 11 y la 12 (sin respuesta en los documentos): 8.
- ¿Qué perilla probarías primero?

# Buscar en los documentos cambió todo




- Llegó el documento correcto, de 11: sin RAG 0, con 1000/150 10, con 400/50 11 (fragmento/overlap).
- Sin RAG no busca: su 0 es por definición. Compará sus respuestas.

# El hit dio bien, pero el fragmento no servía

**Pregunta 7: llega el documento**
**(1 de los 4 fragmentos),**
**ninguno dice RemoveMessage**

→

**Respuestas**
**Modelo chico: «usá Command»**
**Gemini: NO ENCONTRADO**

- El hit mira el documento, no el fragmento.
- ¿Qué mirarías antes de culpar al modelo?

# Mové el tamaño y mirá qué se recupera

## M4 · ¿Qué recupera tu índice?

Solo recuperación: embeddings locales, **sin llamadas pagas**. Antes de mover un control, predecí: ¿aparece el documento esperado? En la tabla, **distancia más chica = fragmento más parecido** a la pregunta.

Pregunta de la suite

¿Qué pasa con los checkpoints de MemorySaver cuando el proceso se reinicia?

Tamaño de fragmento (caracteres) 1,000 Overlap 150 k 4

fragmentos

**189**

esperado: langgraph_persistence

✅ **encontrado**

Search... Columns Explore Export

| # | documento | distancia | fragmento |
|---|---|---|---|
| 1 | langgraph_persistence | 0.984 | **Fix:** Keep `thread_id` values under 255 character... |
| 2 | langgraph_use-subgraphs | 1.185 | The `checkpointer` parameter on `.compile()` contro... |
| 3 | langgraph_persistence | 1.225 | ## Checkpointer vs. store \| \| Checkpointer \| Store \| \|-... |
| 4 | langgraph_persistence | 1.232 | LangGraph provides two complementary persistenc... |

4 rows, 4 columns *No selection*

# Con fragmentos más chicos apareció el correcto

**Fragmentos de 1000**
**pregunta #8**
❌ **fuera de los 4**

→

**Fragmentos de 400**
**pregunta #8**
✅ **4.º de 4: por poco**

#8: ¿qué checkpointer se recomienda en producción? Suite de referencia, 15/10. Con tus documentos, puede ser al revés.

# Para otra pregunta ayudó subir K, no achicar

```
¿Qué clase de LangChain borra mensajes de la memoria?

K = 4, CHUNK = 1000: RemoveMessage: no llegó
K = 8, CHUNK = 1000: RemoveMessage: puestos [5, 8]
K = 4, CHUNK =  400: RemoveMessage: no llegó
en inglés, K = 4   : RemoveMessage: puestos [1, 2, 4]
```

Cada perilla ayuda a unas preguntas y no a otras: por eso se mide con toda la suite.

# Dos búsquedas y un reordenador mejoran el orden




Híbrida: palabras exactas y significado, juntos.

Es opcional: si lo probás, medilo como una variación más.

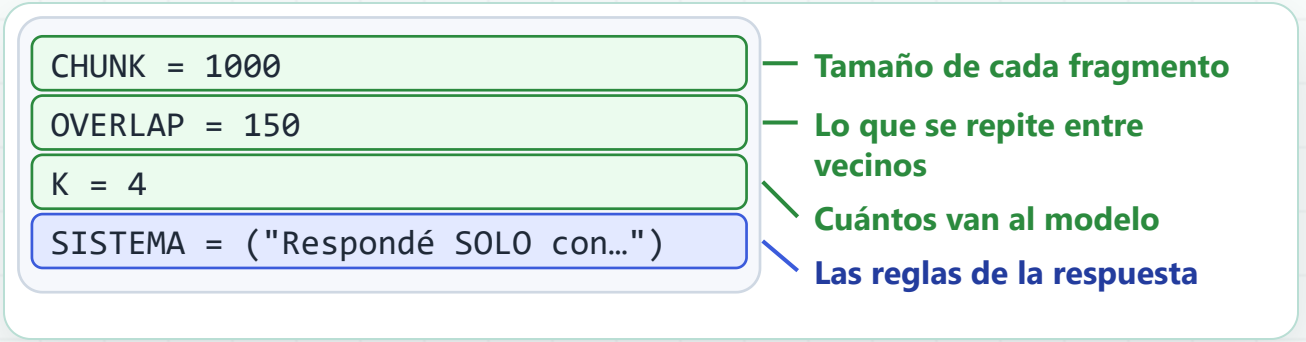
# Una corrida por decisión

```
uv run python suite.py v02_rag:sin_rag datos/mi_suite.jsonl --tag sin-rag
uv run python suite.py v02_rag:con_rag datos/mi_suite.jsonl --tag con-rag
```

Mismo modelo y mismas preguntas: cambia una sola cosa por corrida.

# Taller B: sin documentos, con documentos (45 min)

1. **Suite** sin y con RAG.
2. **Cada fallo:** ¿recuperación o generación?
3. **Una perilla:** `CHUNK`, `OVERLAP` o `K`




Práctica M4, pasos 5 a 8.

**Primer control · 10–15 min:** existe `logs/suite-sin-rag.csv`

# Antes de irte, anotá dónde quedaste

- **Estoy en:** qué paso del taller B.
- **Ya tengo:** el CSV sin RAG, el CSV con RAG o los dos.
- **El lunes sigo con:** la perilla que voy a cambiar.

Una línea en el chat, para retomar el lunes.

# Clínica: una que mejora, una que no

- Una pregunta que mejoró con tus documentos
- Una que no mejoró
- Un límite que no resolviste

Devolución: una fortaleza, un problema y una próxima prueba.

# Repaso: de estas dos clases te llevás tres ideas



**RAG**

buscar antes de responder



**Vectores**

traer los K más cercanos



**Medir**

el hit no dice si es verdad

**Llegar al documento correcto no alcanza: mirá también la respuesta.**

# Cierre de v0.2: ¿dónde no ayudó?

¿En qué pregunta buscar en los documentos no ayudó?

¿Qué cambiarías y qué medirías?

Microdefensa: ¿por qué una respuesta que cita un documento puede estar equivocada?

Anotá tu **confianza (1 a 4)**. Entrega de avance 2: `evidencia/v0.2.md` , *push* hasta el mar 10/11, 23:59.